

KAMP X-ray 이물 탐지 — 데이터 분석 · 실험 결과 보고서

작성일 2026-09-30 (갱신 2026-10-01: 실패 조건 분석, 데이터 다양성 정량화, 합성 결함 설계와 타당성 검증, 옮겨 심기 검증, 스트레스 곡선 v0, 새 베이스라인 YOLOv8s-D-FINE-S 비교; 2026-10-02: 위치 축 스트레스, 사전학습 비교, gVXR 크기·형상·재질 축; 2026-10-06: 팀 결정에 따라 합성 데이터는 평가(test) 전용으로 정리, 판정 기준을 합성 없이 학습한 모델로 다시 정함, 합성 데이터 그림(s3~s5)과 모델 담당용 합성 test 패키지(부록 B.2), 최종 모델·임계값 확정 (§ 5, § 6)) 과제: X-ray 영상 기반 완제품 이물질 탐지 및 AI 미탐지 조건 분석 요구사항: ① 이물 탐지·위치 표시 모델 ② 조건별 성능 변화 분석 ③ 판정 임계값·재검사 기준 제안

0. 요약

구분	내용
데이터	장비 원본 이미지 2,532장 = GT 500장(공식 TXT, 결함 1,147개) + GT 없음 2,020장 + 제외 12장
데이터의 성격	결함이 심어진 표준 테스트피스를 4시간마다 반복 촬영한 장비 점검 영상. 결함은 대부분 2×2px이고 위치는 띠 끝으로 고정
핵심 문제 1	모든 이미지에 장비가 그린 결함 위치 표시(컬러 마커)가 박혀 있음 → 지우지 않으면 모델이 결함 대신 마커를 학습
핵심 문제 2	같은 장비·같은 날 촬영분끼리 비슷함 → 무작위로 나누면 누수
분할	(장비, 날짜) 단위로 train 350 / val 66 / test 84. 모든 실험은 seed 3개로 반복
베이스라인	YOLOv3-SPP (416, COCO 사전학습), 마커 Telea 인페인팅: test AP@0.5 0.935 ± 0.011, P / R@0.25 0.959 / 0.945
실험 ① 마커 처리	7가지 방식(원본·마스킹·인페인팅 5종)을 학습 방식 × 평가 방식 교차표로 비교. 원본·마스킹 학습은 마커를 지운 입력에서 재현율 0.09 / 0.64로 실패. 인페인팅 5종 사이의 차이는 seed 편차 안이며, Telea가 평균이 가장 높고 가장 안정적 → Telea 인페인팅 채택
실험 ② GT 없는 데이터	㉠ 라벨 붙이는 방법 8가지를 GT로 채점(train 3-fold 교차 검증) → 교사 모델 + 구조 필터(T3)가 가장 정확(중심 정밀도 0.999, 채택 이미지에서 놓친 결함 0). ㉢ 그 의사 라벨로 학습해도 학습량을 맞춘 대조군 대비 효과 없음(test AP 차 -0.002 / +0.009) → 학습에 쓰지 않고 검증용으로 사용
실패 조건·다양성	실제 데이터에서 놓친 결함은 3호기의 흐린 결함(CNR ≤ 10)에 몰려 있고, 아예 못 찾은 결함은 0개. 결함의 크기·위치·형상·밀도·배경이 사실상 한 가지라 조건별 성능을 잴 수 없음 → 조건 통제 합성 결함으로 평가하는 설계 (§ 4, 합성은 평가 전용)
실험 ③ 합성 타당성	실제 결함을 지우고 같은 자리에 합성 결함을 다시 넣어 비교. 매개변수 합성(사각 물체 ⊗ 약한 흐림)은 모델 반응은 실제와 같지만, 처리 조건을 맞춰도 분류기가 구별함(AUC 0.95) → 평가 전용. 옮겨 심기(다른 날짜 train 결함의 실제 광학 밀도 맵을 이식, TIP 방식)는 같은 처리를 거친 실제 결함과 거의 구별되지 않음(AUC 0.69 / 0.51) → 조건부 통과. 단 팀 결정(2026-10-06)으로 합성 데이터는 모두 평가(test) 전용이며 학습에 쓰지 않음
스트레스 곡선 v0	실제 결함 자리에서 결함을 열게 하거나 잡음을 더해 검출 한계를 잴(학습 없음). 검출률 50% 지점의 결함 대비는 1·2호기 약 8~9, 3호기 약 16(두 배). 실제 결함 대비 대비 여유가 3호기에서 가장 작음(2.1배). 잡음은 실제의 몇 배를 더해도 견뎌. 두 합성기의 곡선이 일치. 조건이 나빠져도 오검출은 늘지 않고 놓침만 늘어남
새 베이스라인 (§ 3.8)	YOLOv8s-D-FINE-S(COCO 사전학습, 640)로 기존 실험을 다시 함. test AP@0.5 0.958 ± 0.021 / 0.942 ± 0.034(YOLOv3 0.935 ± 0.011). 평균은 높지만 seed 편차 안. val-test 결함 놓침 0. 다만 결함을 지운 자리에도 반응(신뢰도 ≥ 0.25: 21% / 67%, YOLOv3 0.7%) → 결함이 늘 있던 위치를 학습한 지름길. 그래서 새 모델의 스트레스 곡선(밀도 축)은 감도로 해석할 수 없음
위치 축 스트레스 (§ 4.5)	실제 농도의 결함을 원래 자리(띠 끝)가 아닌 제품 안 무작위 자리에 옮겨 심으면 검출률이 YOLOv3 32%, YOLOv8s 41%, D-FINE-S 84%로 떨어짐(원래 자리 98~100%). 대비는 오히려 더 높은 자리들임. 모델이 결함을 보긴 하지만 띠 끝 맥락이 없으면 확신하지 못함 → 현재 test 점수는 다른 위치의 이물에 대한 성능을 크게 과대평가
사전학습 (§ 3.9)	① 없음 / ② COCO / ③ COCO→PIDray: 실제 test는 ② COCO가 가장 좋거나 같음, PIDray 추가 이득 없음. ① 없음은 두 모델 모두 가장 낮음. 위치 지름길은 사전학습과 무관하게 생김(원인은 고정된 결함 위치)

구분	내용
판정 기준 (§ 5)	자동 불량 / 재검사 / 통과 두 임계값을 val로 정함. YOLOv8s ② COCO (합성 없이 학습): test 실제 결함 79% 자동 · 20% 재검사 · 놓침 0.8%, 결함 없는 제품 자동 오판 2.8%, GT 없는 영상 재검사 5.2%. T_high는 결함을 지운 원래 자리의 반응(위치 지름길)이 정함. 다른 자리 결함은 84%를 놓치고 임계값으로 메울 수 없음 → 한계로 보고. 제품 영역 후처리하는 효과 없음(비용이 없어 넣음). 최종 모델 : seed 3개 중 val 최고(seed 1), T_low 0.648 / T_high 0.684, test 놓침 2.4%
gVXR 크기·형상·재질 (§ 4.6)	실제 배경에 gVXR 물리 시뮬레이션 이물을 삽입(실제 결함 = SUS304 구로 보정, 약 0.25 mm, 0.11 mm/px). 모델 반응은 실제 결함과 가장 비슷(상관 0.95~0.98)하나 분류기가 구별 → 평가 전용. 기준보다 작은 이물(×0.5: 0~2%), 큰 이물(×5: 11~65%), 가는 선, 비금속 이물을 놓침 . 모델은 '시편 크기의 금속 점'에 특화. 작은 쪽·비금속은 D-FINE-S ②, 큰 쪽은 YOLOv8s ②가 나옴
모델 담당 전달	handoff/kamp_xray_v2.zip (같은 내용의 .tar.gz 도 있음): 마커 제거 이미지, 고정 분할, YOLO·COCO 라벨, 공통 평가 도구(내부 평가와 소수점까지 일치 확인)

용어

용어	뜻
GT	주최 측 공식 TXT 라벨(정답). 이 보고서의 모든 점수는 공식 TXT 기준
세션	같은 장비가 직전 사진과 10분 이내에 이어져 찍은 사진 묶음. 보통 몇 초 간격으로 약 6장, 약 17초 동안 촬영
(장비, 날짜) 묶음	같은 장비가 같은 날 찍은 모든 사진. 하루 최대 6세션(0·4·8·12·16·20시)
마커	장비가 결함 위치에 그린 18×18px 컬러 사각형 테두리(두께 2px)
인페인팅	마커 픽셀을 지우고 주변 픽셀로 자연스럽게 메우는 것
AP@0.5	예측 박스와 정답 박스가 IoU ≥ 0.5로 겹치면 정답으로 치는 평균 정밀도(101점 보간). 신뢰도 0.001 이상 모든 검출 사용
P / R@0.25	신뢰도 0.25 이상 검출만 남겼을 때의 정밀도 / 재현율
중심거리 지표	IoU 대신 박스 중심 거리 ≤ 8px 이면 맞힌 것으로 칩. 결함은 2×2px인데 정답 박스는 5~21px로 들쭉날쭉해서, "위치를 맞혔는가"를 따로 봄
의사 라벨	GT 없는 사진에 모델(교사)이 붙인 추정 라벨
p990 / p1000	의사 라벨 임계값을 정하는 두 기준. 교사의 val 정밀도가 0.99(p990) / 1.00(p1000) 이 되는 가장 낮은 신뢰도를 임계값으로 씀

1. 데이터

1.1 출처와 구성


모든 이미지는 과제 zip의 **장비 원본 이미지 폴더**에서 가져옵니다.

```
dataset/test1/yolov3/X선이물검출기(06.23_09.22)/{1,2,3}호기/SN*_YYYYMMDD_NgImage/*.bmp
파일 2,809개 = 고유 이미지 2,532장 (날짜 폴더 사이의 중복 복사 277개)
기간 2020-06-22 ~ 09-22, 장비 3대. 파일명 = {제품코드}_{날짜}_{시각}({순번})
```


장비	전체	GT 있음	GT 없음	제외	해상도
1호기	943	156	782	5	352×332, 316×332 (GT 없음에 412×332 추가)
2호기	805	177	623	5	316×332
3호기	784	167	615	2	576×444
합계	2,532	500	2,020	12	

- **GT 있음 500장**: 공식 TXT 라벨(라벨링 6종 세트/labels/*.txt, YOLO 형식, 클래스 1개 Defect)이 있는 이미지. 결함 1,147개. 그중 400장은 라벨링 6종 세트/images 400 과 바이트 단위로 같습니다.
- **GT 없음 2,020장**: 공식 라벨이 없는 이미지 (§ 1.6)

- **제외 12장:** 튜토리얼 예제용 이미지. 공식 라벨이 없고, 규칙이 다른 예제 라벨만 있어 사용하지 않습니다.



1.2 이미지 특성



장비	해상도	컨베이어 배경	제품 영역 밝기	결함 주변 노이즈 σ
1호기	352×332	210 (포화)	143	1.5
2호기	316×332	210 (포화)	106	1.5
3호기	576×444	210 (포화)	122	4.5


- 형식은 8bit 팔레트 BMP이고, 마커를 뺀 모든 픽셀이 R=G=B인 흑백 영상입니다.
- 장비마다 해상도·밝기·노이즈가 다른 **세 개의 도메인**이며, 3호기는 노이즈가 약 3배입니다.

1.3 테스트피스 정기 점검 영상


- GT 이미지의 94%가 **0·4·8·12·16·20시 30분경** 촬영됐습니다 (§ 1.1 그림 오른쪽). 한 번에 **몇 초 간격으로 약 6장**(세션)을 찍습니다.
- 결함은 항상 제품 안 **어두운 띠의 끝**에 있고, 이미지당 결함 수(1개 또는 3개)는 시편 종류(띠 1개 / 3개)로 정해집니다.

- 즉 실제 오염 제품이 아니라, **결함이 심어진 표준 시편을 장비 점검용으로 반복 촬영한 영상**입니다. 이 때문에 결함의 크기·위치·모양이 거의 다양하지 않습니다.

1.4 장비 마커




- 모든 이미지에 장비가 결함 위치에 그린 18×18px 컬러 사각형(선 두께 2px)이 박혀 있습니다.
- 마커 1,144개 중 1,141개가 공식 라벨 결함을 정확히 1개씩 감싸고, 94%는 마커 중심과 라벨 중심의 거리가 2px 이내입니다. → **마커를 그대로 두면 모델이 결함 대신 마커를 학습할 수** 있습니다.
- 과제 안내: 마커는 탐지 특징으로 사용 금지, 공식 정답은 TXT, 제거·마스킹·인페인팅은 허용(방법·영향 명시). → 마커는 **제거 대상**으로만 다룹니다(§ 3.2).




- 1·2호기 마커의 97~98%는 빨강 단색입니다. 여러 색은 대부분 3호기에서 나오며, 같은 크기의 박스 여러 개가 1~2px 어긋나 겹쳐 그려진 것입니다. 장비 내부 판정 채널별 표시로 추정됩니다. 3호기의 자홍색은 6월에만 나타납니다.

1.5 결함 특성




장비	GT 박스 (중앙값)	결함 코어 면적 (반치폭)	416 입력 기준 코어 한 변
1호기	$9 \times 9\text{ px}$	4 px	$\approx 2.4\text{ px}$
2호기	$10 \times 10\text{ px}$	4 px	$\approx 2.5\text{ px}$
3호기	$13 \times 12\text{ px}$	5 px	$\approx 1.6\text{ px}$

- 실제 결함은 거의 모두 $2 \times 2\text{px}$ 점입니다. 라벨 박스는 결함보다 면적 기준 약 25배 크고, 같은 결함에도 5~21px로 들쭉날쭉합니다. → 평가 시 IoU 매칭과 함께 중심거리 매칭($\leq 8\text{px}$)도 보고합니다.
- 416 입력에서 결함 코어는 1.5~2.5px로, YOLOv3의 최소 stride(8)보다 작습니다.




- 결함은 100% 제품 내부에 있고, 제품 외곽선까지 최소 36px 떨어져 있습니다. 제품 가장자리 결함은 0건입니다.



- 결함은 주변보다 국소 밝기의 약 35%만큼 어둡습니다(곰셈형 감쇠). 배경이 어두운(두꺼운) 부위일수록 절대 대비가 작아 집니다($r = 0.64$).


- 모든 결함이 $CNR \geq 5$ (최소 5.1, 중앙값 16)라서, 눈으로 봐도 애매한 결함은 없습니다. 3호기가 노이즈 때문에 CNR이 가장 낮습니다(중앙값 8.4).



1.6 라벨 품질



점검	결과
형식 오류·범위 이탈	0건
마커는 있는데 TXT 라벨이 없는 결함	1건 (002_20200623_123055(5)). 과제 안내에 따라 TXT 를 우선해 라벨을 추가하지 않으며, 평가에서 모델이 이를 검출하면 오검출로 집계됩니다
TXT 라벨은 있는데 마커가 없는 결함	1건 (001_20200629_082834(2)). 라벨은 유효
라벨 중심 ↔ 실제 결함 중심	평균 (0.5, 0.0)px 차이. 위치는 정확함
과제 제공 가중치 (last*.pt)	과거 무작위 분할의 test 이미지를 학습에 사용한 상태라 평가·초기값으로 쓰지 않음

1.7 GT 없는 데이터



항목	GT 있음	GT 없음
촬영 날짜	장비별 10~17일에 몰려 있음	전 기간(장비별 42~45일). 66%가 GT가 한 장도 없는 날짜
해상도	576×444 / 352×332 / 316×332	추가로 412×332 (1호기 120장)
시편 종류	결함 3개짜리 64%	결함 1개짜리 65%

항목	GT 있음	GT 없음
제품 밝기	장비별 143 / 106 / 122	같은 범위 (분포만 조금 넓음)
마커	모두 있음	모두 있음 (장비 불량 판정 저장본) → 같은 방식으로 제거



이상 이미지 107장

GT 없는 데이터의 이상 이미지 107장 (원본, 장비 표시 포함) — 학습 제외, 헛검출 점검용

제품이 화면 밖으로 잘림
(1호기 7/27, 104장)

제품 없음
(1호기 7/27)

결합 대신 "T" 표시
(2호기 9/4, 2장)

표시가 제품 밖
(1호기 7/13, 1장)

유형	장수	내용
비정상 촬영	104	1호기 7/27 한 세션. 제품이 화면 밖으로 잘리거나 없음. 제품 밖 컨베이어에 작은 얼룩이 찍힌 이미지 포함
"T" 표시	2	2호기 9/4. 결합 표시 대신 빨간 "T" 글자


유형	장수	내용
제품 밖 표시	1	1호기 7/13

- 정상 이미지는 1,913장입니다. 이상 이미지는 학습에 쓰지 않고, 예외 입력에서 헛검출이 나는지 점검하는 데만 씁니다.

2. 누수 방지 분할

2.1 왜 누수가 생기나

같은 장비가 같은 테스트피스를 몇 초 간격으로 약 6장씩(세션), 4시간마다 찍습니다. GT 500장에는 세션이 113개 있고, 세션당 중앙값 6장, 세션 길이는 약 17초입니다.



- 같은 장비의 GT 사진 쌍끼리 차이값(dHash 거리, 작을수록 비슷)을 비교하면, 중앙값이 **같은 세션 28 → 같은 날 다른 세션 34 → 다른 날 37**입니다. 개별 쌍은 제품이 놓인 위치에 따라 들쭉날쭉하지만, 분포로 보면 가까운 시간에 찍은 사진일수록 비슷합니다.
- 그래서 **같은 날 사진**이 train과 test에 나뉘어 들어가면, 모델이 시험에 나올 사진과 비슷한 사진으로 미리 학습한 셈이 되어 점수가 부풀려집니다.

2.2 분할 규칙

항목	결정
대상	GT 있는 500장. val·test는 정답과 비교해야 하므로 GT가 있는 사진만 씀
묶음 단위	(장비, 날짜): 같은 장비·같은 날 촬영분은 모두 한 split에만 들어감
균형	장비(3) × 시편 종류(결함 1개 / 3개)별로 비율을 맞춤
배정	총마다 날짜 묶음을 train / val / test에 배정하는 조합을 무작위로 2만 번 시도(seed 42)해, 70 / 15 / 15에 가장 가까운 것을 선택. 날짜 묶음이 3개 이상인 층은 val·test에 최소 1개씩 배정
역할	train 학습 · val 최적 시점 모델 선택, 의사 라벨 임계값 결정 · test 최종 성적에만 사용(방법 선택에 쓰지 않음)
반복	모든 실험 조건을 seed 0·1·2로 3번 학습해 평균 ± 표준편차로 비교. seed만 바뀌어도 AP가 0.01~0.05 흔들리기 때문

- "세션은 자동으로 함께 묶인다"의 뜻: 세션은 몇 초~몇십 초짜리 촬영이라 항상 하루 안에 끝납니다. 따라서 날짜 단위로 묶으면, 한 세션의 사진이 두 split으로 갈라지는 일이 저절로 없어집니다. 세션보다 큰 단위(날짜)로 묶은 이유는, 같은 날의 다른 세션끼리도 다른 날보다 비슷하기 때문입니다 (§ 2.1).
- 날짜보다 더 큰 단위(주·월)는 쓰지 않았습니다. GT가 있는 날짜가 장비별로 10~17일뿐이라, 더 크게 묶으면 val·test에 넣을 묶음이 모자랍니다.

2.3 결과

split	1호기	2호기	3호기	합계	결함	날짜	(장비, 날짜) 묶음	세션
train	99	134	117	350 (70%)	797	12	17	77
val	26	18	22	66 (13%)	144	9	11	15
test	31	25	28	84 (17%)	206	8	9	21

- 같은 (장비, 날짜)나 같은 세션이 두 split에 걸친 경우는 0건입니다(코드로 검증).
- 날짜 묶음 하나가 커서(하루 최대 36장) 비율이 70 / 15 / 15에서 조금 벗어났습니다.

2.4 GT 없는 데이터의 배치


GT 없는 사진은 점수를 매길 수 없으므로 **학습 쪽에만** 추가할 수 있습니다. 사진마다 "그날 같은 장비의 GT 사진이 어느 split에 있는지"를 보고 역할을 정했습니다(`prep/build_unlabeled.py`, seed 42).

역할	장수	기준	용도
학습 가능	1,244	train과 같은 (장비, 날짜) 38장 + GT가 없는 (장비, 날짜)의 70% 1,206장	의사 라벨 대상 후보
평가용	560	GT가 없는 (장비, 날짜)의 30%. 날짜 단위로 나눔	처음 보는 날짜에서의 검출 일관성 (참고 지표)
제외	109	val(79장)·test(30장)와 같은 장비·같은 날	학습에 쓰면 평가 누수 → 사용하지 않음
이상 이미지	107	§ 1.7	헛검출 점검용

제외 109장을 따로 둔 이유: 이 사진들은 val·test의 GT 사진과 **파일은 다르지만**, 같은 장비가 같은 날 같은 시편을 찍은 것입니다. § 2.1과 같은 이유로, 이 사진으로 학습하면(의사 라벨이라도) val·test와 비슷한 사진을 미리 본 셈이 됩니다. GT 사진끼리 날짜 단위로 나눈 규칙을 GT 없는 사진에도 똑같이 적용한 것입니다.

예: 3호기 2020-09-22에는 GT 사진 2장이 **val**에 있습니다. 같은 날 찍힌 GT 없는 사진 27장은 학습에서 뺐습니다.

3호기 2020-09-22: val 사진 2장과 같은 날 찍힌 GT 없는 사진 → 같은 시편·같은 장비·같은 날이라 학습에서 제외



3. 실험

3.1 공통 설정

항목	내용
모델	YOLOv3-SPP (과제 제공 코드에 PyTorch 2.7 호환 패치), 클래스 1개
초기값	COCO 사전학습 가중치 (외부 데이터, § 3.7)
학습	SGD + cosine LR(lr0 0.01), 배치 16 × 누적 4 = 실효 배치 64, 300 epoch. 증강은 코드 기본값(mosaic, 크기 320~640 multi-scale, HSV, 좌우 뒤집기). best.pt = val 점수가 가장 높은 시점
입력	8bit 흑백 PNG(마커 제거본). 평가 입력 크기 416
평가	공식 TXT 기준. NMS(IoU 0.5) 후 신뢰도 0.001 이상 모든 검출로 AP@0.5, 신뢰도 0.25에서 P-R, 중심거리(≤ 8px) 매칭. 이미지마다 신뢰도 높은 검출부터 아직 짝이 없는 정답과 짝지움
반복	seed 0·1·2 (가중치 초기화·데이터 순서·증강이 달라짐). 표의 값은 평균 ± 표준편차
실험 설계	요인별 단독 실험: 한 요인만 바꾸고 나머지는 베이스라인으로 고정. 요인 = ① 마커 처리 ② GT 없는 데이터 활용 ③ 데이터 다양성 ④ 모델. 각 요인의 선택이 끝나면 선택한 방법끼리 조합해 다시 실험

3.2 실험 ①: 마커 처리 방식

3.2.1 마커를 찾고 지우는 절차

- 마커 찾기:** 원본은 8bit 팔레트 BMP입니다. RGB로 바꾸면 X-ray 영상 픽셀은 모두 $R=G=B$ (무채색)이고, 장비가 그린 마커만 유채색입니다. 그래서 **$R \neq G$ 또는 $G \neq B$ 인 픽셀 = 마커**로 마스크를 만듭니다. 사람이 손으로 표시하거나 모델이 추정하는 과정은 없습니다.
- 지우기:** 흑백으로 바꾼 영상에서 마스크 픽셀만 아래 방법으로 새 값을 채우고, 나머지 픽셀은 그대로 둡니다.
- 라벨:** 공식 TXT를 수정 없이 그대로 씁니다. 마커 위치는 라벨 생성이나 평가에 쓰지 않습니다.

조건	방법	쉽게 말하면
원본	마커를 그대로 둠	비교용. 마커를 특징으로 쓰는 셈이라 제출 불가
마스킹	마커 픽셀을 회색 128로 칠함	마커 모양의 회색 테두리가 남음
Telea (베이스라인)	<code>cv2.inpaint(TELEA, 반경 3)</code>	테두리 바깥쪽부터 안쪽으로, 가까운 픽셀의 밝기와 기울기를 이어 붙여 메움
Navier-Stokes	<code>cv2.inpaint(NS, 반경 3)</code>	밝기의 등고선이 끊기지 않게 흐르듯 이어서 메움
2px 확장 + Telea	마스크를 3×3 팽창 2회로 2px 넓힌 뒤 Telea	마커 가장자리의 번짐까지 확실히 지움. 대신 바뀌는 픽셀이 약 3배
배경 채우기	마스크 밖 픽셀만으로 가우시안($\sigma=3$) 가중 평균	주변 평균 밝기로 메움 (구조를 잊지 않음)
Biharmonic	<code>skimage.restoration.inpaint_biharmonic</code>	메운 영역이 경계에서 가장 매끄럽게 이어지도록 수식으로 풀

지우기가 데이터에 준 영향

항목	Telea · NS · 배경 채우기 · Biharmonic	2px 확장 + Telea
바뀐 픽셀	이미지당 평균 0.22% (128~496px)	0.64%
결함 중심 ↔ 가장 가까운 지운 픽셀	최소 5px, 중앙값 7px	최소 3px, 중앙값 5px
결함 코어(2×2 px)를 건드렸나	아니오 (1,147개 모두)	아니오 (2px 이내 0개)
GT 박스와 겹침 (Telea 기준)	박스 내부 픽셀의 1.75%(박스 가장자리), 86/500장	더 넓음

- GT 없는 데이터의 특수 표시("T" 글자, 가장자리 세로선)도 같은 방식으로 흔적 없이 지워집니다.

3.2.2 평가를 어떻게 공정하게 했나

실제 생산 라인 영상에는 마커가 없습니다. 그래서 "마커 없는 영상에서 결함을 찾는가"가 배포 성능입니다. 그런데 **GT 500장은 모두 마커가 박혀 있어, 진짜 마커 없는 평가 이미지는 존재하지 않습니다.** 어떤 방식으로든 지운 test를 써야 합니다.


문제: Telea로 지운 test 하나로만 평가하면, Telea로 학습한 모델이 "자기와 같은 방식으로 지운 입력"을 받으므로 유리할 수 있습니다.

대응 두 가지

- 교차표:** 7가지 방식으로 각각 학습($\times$ seed 3 = 21개 모델)하고, 모든 모델을 7가지 방식으로 지운 test 각각에서 평가했습니다. 한 학습 방식이 **다른 방식으로 지운 입력에서도 잘 되는지**를 보면, 특정 채우기 방식에 대한 유불리를 걸러낼 수 있습니다. 배포 성능의 대표값은 **인페인팅 5종 test의 평균**으로 정했습니다. 원본·마스킹 test는 마커나 회색 테두리가 남아 있어 "마커 없는 영상"이 아니므로 대표값에서 뺐습니다.
- 흔적 검사:** 채운 자국 자체가 모델의 단서가 되는지 직접 확인했습니다. 교차표만으로는 "결함 옆에 채운 자국이 있으면 결함"이라는 지름길을 배웠는지 알 수 없기 때문입니다.
 - 대상: val·test 150장. 이미지마다 **결함이 없는** 제품 내부 위치 3곳(총 450곳)을 고릅니다. 링 전체가 제품 안에 들어가고, 정답 결함·다른 위치와 30px 이상 떨어져야 합니다.

- 방법: 그 위치에 실제 마커와 같은 18×18px·두께 2px 링 마스크를 만들고, 링 픽셀을 각 방식으로 지웁니다(회색 링은 128로 칠함). 결함은 없고 흔적만 생긴 셈입니다.
- 판정: 링 중심 8px 안에 신뢰도 0.1(또는 0.25) 이상 검출이 생기면 "반응"으로 셉니다. 흔적을 넣기 전 같은 위치의 반응률(대조군)은 모든 모델에서 0~0.2%였습니다.
- 위치는 모든 방식·모델에서 같습니다(난수 seed 0).

3.2.3 결과



학습 방식	자기 방식 test AP	인페인팅 5종 test 평균 AP	인페인팅 5종 test 평균 R@0.25	흔적 반응: 자기 방식 링 ¹	흔적 반응: 회색 링 ¹
원본	0.899 ± 0.027	0.646 ± 0.091	0.087 ± 0.080	0% (Telea 링)	31.0% / 7.5%
마스킹	0.866 ± 0.061	0.708 ± 0.093	0.639 ± 0.029	47.8% / 15.3%	47.8% / 15.3%
Telea	0.935 ± 0.011	0.924 ± 0.015	0.937 ± 0.006	0.2% / 0%	1.6% / 0%
Navier-Stokes	0.901 ± 0.043	0.901 ± 0.041	0.922 ± 0.013	0.1% / 0.1%	0.5% / 0%
2px 확장 + Telea	0.912 ± 0.048	0.917 ± 0.027	0.874 ± 0.034	4.0% / 0.9%	29.6% / 7.4%
배경 채우기	0.898 ± 0.050	0.896 ± 0.046	0.918 ± 0.017	0.2% / 0%	7.2% / 0.8%
Biharmonic	0.887 ± 0.025	0.910 ± 0.010	0.911 ± 0.013	0.1% / 0%	0.1% / 0%

¹ 결함 없는 450곳 중 반응 비율, 신뢰도 ≥ 0.1 / ≥ 0.25

인페인팅 5종 test 평균 AP의 seed별 짝 비교 (각 방식 - Telea)

방식	seed 0	seed 1	seed 2	평균
Navier-Stokes	-0.031	+0.036	-0.075	-0.024
2px 확장 + Telea	-0.001	+0.030	-0.050	-0.007
배경 채우기	-0.043	+0.038	-0.081	-0.029
Biharmonic	-0.026	-0.002	-0.015	-0.014

읽는 법

- 원본·마스킹 학습은 어떤 방식으로 지운 입력에서도 실패합니다. 원본 학습 모델의 재현율은 인페인팅 5종 모두에서 0.05~0.13, 마스킹 학습 모델은 0.56~0.73입니다. Telea 입력에서만 나쁜 것이 아니므로, 앞선 결론(원본·마스킹 탈락)은 평가 입력 선택 때문이 아닙니다.
- Telea로 학습한 모델은 다른 방식으로 지운 입력에서도 AP 0.90~0.93, 재현율 0.91~0.95를 유지합니다. 즉 Telea 모델의 성적은 "Telea 입력이라서"가 아닙니다.

- **인페인팅 5종끼리의 차이는 seed 편차 안입니다.** 짝 비교의 부호가 seed마다 바뀌고(Biharmonic 제외), 차이 크기가 seed 간 편차(0.01~0.05)와 비슷합니다. 다만 **Telea보다 평균이 높은 방식은 없고**, 자기 방식 test 기준으로 Telea의 seed 편차가 가장 작습니다(± 0.011).
- **2px 확장 + Telea는 흔적이 단서가 됩니다.** 자기 방식 링에 4.0%, 회색 링에 29.6% 반응합니다. 넓게 지우면 매끈하게 메운 영역이 결함 3px 앞까지 와서, "사각형 모양의 매끈한 테두리 안쪽 = 결함"이라는 연관을 배운 것으로 추정됩니다. 재현율도 인페인팅 중 가장 낮습니다(0.874).
- 배경 채우기 모델도 회색 링에 7.2% 반응해 Telea(1.6%)보다 흔적에 민감합니다.
- 마스킹 test(회색 테두리가 남은 입력) 열에서 인페인팅 모델들의 점수가 높은 것(AP 0.95~0.96)은 참고용입니다. 배포 영상에는 회색 테두리가 없으므로 판단에 쓰지 않았습니다.

결론

- **Telea 인페인팅(반경 3)을 유지합니다.** 평균 성능이 가장 높고, seed 간 편차가 가장 작고, 다른 채우기 방식의 입력에도 강하며, 흔적이 단서가 되지 않습니다.
- 원본 학습은 마커 없는 영상에서 결함의 약 91%를 놓치고, 마스킹은 회색 링 자체가 새 지름길이 되어 결함이 없는 곳의 절반 가까이에서 반응합니다.
- **남는 한계:** 진짜 마커 없는 영상으로는 검증하지 못했습니다. 주최 측이 마커 없는 라인 영상을 제공하면 그걸로 확인하는 것이 가장 확실합니다.

3.3 베이스라인

seed	test AP@0.5	P@0.25	R@0.25	중심거리 R@0.25
0	0.943	0.961	0.951	0.990
1	0.923	0.956	0.942	0.985
2	0.940	0.960	0.942	0.981
평균	0.935 $\pm$ 0.011	0.959 $\pm$ 0.003	0.945 $\pm$ 0.006	0.985 $\pm$ 0.005

- 중심거리 AP는 0.995로, 결함 위치는 거의 다 맞습니다. 남은 오차는 박스 크기와 신뢰도에서 나옵니다. 라벨 박스 크기가 들쭉날쭉한 영향입니다(§ 1.5).
- val AP는 0.951 $\pm$ 0.015입니다.
- 장비별 test AP(seed 0): 1호기 0.984, 2호기 0.946, **3호기 0.887**. 3호기는 노이즈가 약 3배이고, 416으로 줄이면 결함이 1.6px까지 작아집니다.

3.4 실험 ②: GT 없는 데이터 활용

이 실험은 두 질문으로 나뉘었습니다.

- ① 어떤 방법으로 라벨을 붙여야 정확한가? → GT가 있는 사진에서 여러 방법을 채점(§ 3.4.1)
- ② 그렇게 만든 의사 라벨이 학습에 도움이 되는가? → GT만 vs GT + 의사 라벨(§ 3.4.2)

3.4.1 ① 의사 라벨 방법 비교 (GT로 채점)

GT 없는 사진은 정답이 없어서 라벨 품질을 잴 수 없습니다. 그래서 **GT가 있는 train 사진을 GT 없는 사진인 척** 놓고, 각 방법이 붙인 라벨을 공식 TXT와 비교했습니다.

설계: train 3-fold 교차 검증 (prep/build_cv_folds.py, eval/pseudo/pl_methods_cv.py)

- train 350장을 (장비, 날짜) 묶음 단위로 3조각으로 나눴습니다(총 = 장비 $\times$ 시편 종류, seed 42). 같은 날 사진은 같은 조각에 들어갑니다.

조각	이미지	결함	묶음	1호기 / 2호기 / 3호기
0	115	210	7	27 / 72 / 16

조각	이미지	결합	묶음	1호기 / 2호기 / 3호기
1	87	231	4	36 / 0 / 51
2	148	356	6	36 / 62 / 50


- 조각 k마다 나머지 두 조각으로 교사를 학습(베이스라인과 같은 설정, 300 epoch, seed 0)하고, 조각 k의 사진에 라벨을 붙여 채점합니다. 교사는 채점할 사진을 학습에서 본 적이 없습니다.
- 교사의 최적 시점 선택과 임계값 T는 공식 val로 정했습니다(val 정밀도 ≥ 0.99가 되는 최소 신뢰도: 조각별 T = 0.103 / 0.134 / 0.144). test는 쓰지 않았습니다.
- 세 조각의 결과를 합쳐 train 350장 전체(결합 797개)로 채점했습니다.
- 한계: 날짜 묶음이 곱아서 조각마다 장비 구성이 고르지 않습니다(조각 1에 2호기 없음). 교사가 train의 2/3로만 학습해서, 실제 교사(train 전체로 학습)보다 조금 약합니다.

비교한 방법 8가지

이름	방법	마커 사용
MK	원본 마커(연결 성분)의 중심에 박스. 박스 크기 = 교사 학습 조각의 장비별 GT 박스 크기 중앙값. 제품 밖 마커 제외	사용
T0	교사 검출 중 신뢰도 ≥ T	—
T1	T0 + 제품 영역 밖 검출 제외	—
T2	T1 + 이미지당 검출 수가 1 또는 3인 이미지만 채택 (시편 구조)	—
T3	T2 + 애매한 검출($0.10 \leq \text{신뢰도} < T$)이 있는 이미지는 통째로 제외 (실험 ②⑥에 쓴 방법)	—
T4	T3 + 같은 세션 사진들의 검출 수 최빈값과 같은 이미지만 채택	—
H1	교사 검출(신뢰도 ≥ 0.05, 제품 안) 중 마커 중심 8px 안에 있는 것만	사용
H2	마커 위치마다 8px 안에 교사 박스(신뢰도 ≥ 0.01)가 있으면 그 박스, 없으면 MK 박스	사용

- 제품 영역 = 밝은 컨베이어 배경과 구분되는 가장 큰 어두운 영역(Otsu 이진화 → 열림 → 최대 연결 성분 → 구멍 채움).
- 마커를 쓰는 방법(MK·H1·H2)은 규칙상 회색 지대라 "채택 시 주최 측 확인 필요" 후보로 넣었습니다. 마커를 모델 입력 특 징으로 쓰는 것은 아니지만, 라벨 생성에 쓰기 때문입니다.

결과 (train 350장, 결합 797개)



방법	채택 이미지	박스 정밀도 (IoU $\geq$ 0.5)	박스 정밀도 (중심)	채택 이미지에서 놓친 결함	완전 일치 이미지	전체 결함 중 얻은 비율
T3 (현재)	96.3%	0.966	0.999	0	0.997	0.964
T4	95.4%	0.966	0.999	0	0.997	0.952
H1 (혼합)	100%	0.900	0.931	6	0.843	0.992
H2 (혼합)	100%	0.958	0.995	6	0.986	0.992

- 완전 일치 이미지 = 그 이미지의 의사 라벨이 정답과 하나도 안 틀린 비율(빠진 결함도, 틀린 박스도 없음)

읽는 법

- T2~T4의 중심 기준 오류는 1개뿐이고, 그 1개도 실제 결함입니다. 002_20200623_123055(5)의 결함은 마커가 있고 모델도 찾지만 공식 TXT에 라벨이 없는 사례입니다 (§ 1.6). 사실상 틀린 라벨이 없습니다.
- 구조 필터(검출 수 1 또는 3)가 핵심입니다. T1에서 T2로 가면서 놓친 결함 6개가 모두 사라집니다. 교사가 결함을 놓친 이미지는 검출 수가 2개처럼 구조에 안 맞게 나와서 걸러집니다. 대가로 이미지의 2.6%를 버립니다.
- T3·T4의 추가 필터는 정확도를 더 올리지 못하고 이미지만 더 버립니다. T2와 T3는 사실상 같은 품질입니다.
- 마커 방식(MK)은 교사 방식보다 정확하지 않습니다. 놓친 결함이 6개(마커가 없는 결함 포함), 중심 기준으로 틀린 박스가 4개입니다. 필터가 없어 틀린 이미지를 걸러내지 못합니다.
- 혼합 방식은 이득이 없습니다. H1은 한 마커 주변의 낮은 신뢰도 검출이 여러 개 겹쳐 들어와 정밀도가 0.93으로 떨어집니다. H2는 MK와 거의 같습니다.
- IoU 기준 정밀도(0.96~0.97)가 중심 기준(0.999)보다 낮은 것은, 위치는 맞지만 박스 크기가 정답 박스와 달라서입니다. 정답 박스 크기 자체가 들쭉날쭉하기 때문입니다 (§ 1.5). 장비별 IoU 기준 정밀도(T3): 1호기 0.966, 2호기 0.993, 3호기 0.935.

결론: 교사 + 구조 필터(T3)를 유지합니다. 가장 정확하고, 마커를 쓰지 않아 규칙 문제도 없습니다. T3는 실험 ②⑥에서 이미 쓴 방법이라 추가 학습은 하지 않았습니다.

3.4.2 ⑥ 의사 라벨로 학습하면 도움이 되는가

방법

1. **교사:** 베이스라인(seed별 3개, train 350장 전체로 학습)
2. **의사 라벨 생성:** 교사가 "학습 가능" 1,244장 (§ 2.4)에서 결함을 검출하고, T3 조건을 모두 만족하는 이미지만 씁니다.
 - 신뢰도 $\geq$ T. T는 교사의 val 정밀도가 0.99(p990) 또는 1.00(p1000)이 되는 가장 낮은 신뢰도입니다. val 검출을 신뢰도 높은 순으로 줄 세우고, 위에서부터 누적 정밀도가 목표 이상을 유지하는 가장 낮은 신뢰도를 고릅니다. 1.00은 "val에서 틀린 검출이 하나도 섞이지 않는 선"이라 더 엄격합니다.
 - 제품 영역 밖 검출은 제외합니다. 과제 대상이 제품 내부 이물이기 때문입니다.
 - 이미지당 검출 수가 1 또는 3으로 시편 구조와 맞아야 합니다.
 - 애매한 검출($0.10 \leq$ 신뢰도 $< T$)이 있는 이미지는 통째로 제외합니다. 교사가 놓친 결함이 "배경"으로 학습되는 것을 막기 위해서입니다.
3. **학생:** 베이스라인 설정으로 COCO 초기값에서 새로 학습합니다. 데이터는 GT train 350장 + 의사 라벨 이미지, 100 epoch입니다. 데이터가 약 4배라 이미지 처리량은 베이스라인 300 epoch의 약 1.4배입니다.
4. **학습량 대조군:** 의사 라벨 대신 GT train 350장을 반복해서, 학생과 같은 목록 크기·epoch·LR 스케줄로 학습합니다. 학생과 비교하면 학습량 차이가 빠지고 GT 없는 데이터의 순수 효과만 남습니다.

기준	임계값 T (seed 0 / 1 / 2)	의사 라벨 이미지	의사 라벨 결함
p990 (정밀도 0.99)	0.167 / 0.181 / 0.215	1,161 ~ 1,187	2,001 ~ 2,039
p1000 (정밀도 1.00)	0.203 / 0.237 / 0.270	1,152 ~ 1,165	1,982 ~ 1,993


- 두 기준의 의사 라벨은 98~99% 같습니다. p1000 결과가 p990의 부분집합이고, 공통 이미지의 라벨은 100% 동일합니다. 그래서 두 조건은 거의 같은 데이터로 한 번 더 학습한 반복 실험으로도 읽을 수 있습니다.

의사 라벨 품질 (val 66장에 같은 절차를 적용해 공식 TXT와 비교)

교사	필터 통과율	의사 라벨 정밀도	통과 이미지에서 농진 결함
seed 0 / 1 / 2	88~94%	1.00	0

임계값을 같은 val에서 정했으므로 낙관적인 추정입니다. § 3.4.1의 교차 검증(임계값을 정한 사진과 채점한 사진이 다름)에서도 중심 기준 정밀도 0.999로 같은 결론입니다.

결과



지표	베이스라인	학습량 대조군	의사 라벨 (p990)	의사 라벨 (p1000)
test AP@0.5	0.935 ± 0.011	0.915 ± 0.013	0.913 ± 0.021	0.925 ± 0.018
test R@0.25	0.945 ± 0.006	0.942 ± 0.005	0.940 ± 0.012	0.937 ± 0.005
test P@0.25	0.959 ± 0.003	0.946 ± 0.005	0.945 ± 0.008	0.954 ± 0.010
val AP@0.5	0.951 ± 0.015	0.963 ± 0.005	0.965 ± 0.012	0.952 ± 0.007
GT 없는 평가용 560장: 구조 일치율 / 검출 0개 비율 ¹	0.971 / 0.009	0.977 / 0.007	0.989 / 0.002	0.967 / 0.011
이상 이미지 107장 헛검출 비율 ¹	0.028	0.028	0.028	0.028

¹ 정답이 없는 참고 지표. 구조 일치율 = 신뢰도 0.25 이상 검출 수가 1 또는 3인 이미지 비율(제품 밖 검출 제외)

seed별 짝 비교 (test AP 차)

- 대조군 - 베이스라인: -0.041 / +0.005 / -0.023 (평균 -0.020)
- 의사 라벨(p990) - 대조군: +0.015 / -0.036 / +0.015 (평균 -0.002)
- 의사 라벨(p1000) - 대조군: +0.044 / -0.013 / -0.003 (평균 +0.009)

결론

- GT 없는 데이터의 순수 효과는 없습니다.** 학습량을 맞춘 대조군 대비 test AP 차이가 평균 -0.002 / +0.009이고, 부호가 seed마다 바뀝니다.
- 학습량 증가 자체는 val을 올리고(+0.012) test를 약간 낮춥니다(-0.020). 대조군 없이 학생과 베이스라인만 비교했다면 "의사 라벨이 해롭다"고 잘못 결론 내렸을 것입니다.
- 의사 라벨이 98~99% 같은 두 조건의 결과가 ±0.01~0.02 차이 나므로, 이 크기의 차이는 우연 범위입니다.
- 원인: GT 없는 데이터도 같은 테스트피스를 같은 위치에서 찍은 영상이라, 라벨이 정확해도 모델에 새 정보를 주지 못합니다.
- GT 없는 데이터는 학습에 쓰지 않고, 처음 보는 날짜에서의 검출 일관성 확인과 이상 입력 점검에 씁니다.**

3.5 실제 데이터의 실패 조건 분석

질문: 지금 모델은 실제 데이터에서 언제 결함을 놓치나?

방법 (eval/failure/collect_heldout.py, failure_analysis.py)

- GT 결함 1,147개 전부를, **그 사진을 학습에 쓰지 않은 모델**로 채점했습니다.
 - val-test 150장(결함 350개): 베이스라인 seed 3개
 - train 350장(결함 797개): 실험 ②③의 교차 검증 교사 (해당 조각을 학습하지 않은 교사, seed 0)
- 결함마다 **결함 중심 8px 안 검출의 최대 신뢰도**를 구합니다. 0.25 미만이면 "놓침"으로 셉니다. 놓침 비율을 결함 조건(장비, CNR, 배경 밝기, 크기, 위치, 시간대 등)별로 비교했습니다.

결과

조건	결함 수 (×모델)	놓침 (신뢰도 < 0.25)
1호기	678	1.0%
2호기	582	0.2%
3호기	587	5.6%
3호기, CNR ≤ 8	253	4.7%
3호기, CNR 8~10	154	10.4%
3호기, CNR > 10	180	2.8%
1·2호기, CNR ≤ 10	45	2.2%
1·2호기, CNR > 10	1,215	0.6%
3호기 2020-06-24 하루	102	17.6%

- 아예 못 찾은 결함은 0개입니다.** 놓침 41건 모두 결함 위치에 신뢰도 0.07~0.25로 반응했습니다. 모델이 보지 못하는 영역이 있는 게 아니라 확신이 약한 경우입니다.
- 놓침은 3호기의 흐린 결함(CNR ≤ 10)에 몰려 있습니다.** 3호기는 잡음이 약 3배이고, 416 입력에서 결함이 1.4px로 가장 작습니다.
- 크기, 제품 가장자리 거리, 배경 밝기, 시편 종류로 나눈 차이는 대부분 장비 차이로 설명됩니다. 3호기가 이미지가 커서 가장자리 거리가 길고, 배경 밝기도 중간 구간에 있기 때문입니다.
- AP를 깎는 주원인은 박스 크기입니다.** 위치를 맞힌 검출 1,806건 중 61건(3.4%)이 IoU < 0.5였습니다. 이때 정답 박스는 예측 박스의 약 0.70배(중앙값)로 더 작습니다. 라벨 박스 크기가 들쭉날쭉한 영향입니다(§ 1.5).
- 신뢰도 0.25 이상 오검출은 1,847건 중 2건뿐입니다(중심 기준).

결론: 실제 데이터에서 찾을 수 있는 약점은 **"잡음 많은 장비의 흐린 결함"** 하나입니다. 그 밖의 조건은 데이터에 변화가 없어서 약점인지 아닌지조차 알 수 없습니다(§ 3.6).


3.6 데이터 다양성 정량화

질문: 과제가 요구하는 "이물 조건(크기·위치·형상·밀도·대비)에 따른 성능 변화"를 지금 데이터로 잴 수 있나?

방법 (eda/diversity.py): 결함 1,147개마다 결함 코어 주변 12×12px를 잘라 아래 값을 측정했습니다.

- 감쇠율** $a = 1 - I / I_{\text{배경}}$: 결함이 X선을 얼마나 가리는지. 0이면 그대로 통과, 1이면 완전 차단
- 광학 밀도** $OD = -\ln(1 - a)$: Beer-Lambert 법칙에서 $OD = (\text{재질의 감쇠 계수} \times \text{두께})$ 이므로, **재질 밀도 × 두께**의 대리 지표
- 크기**: 최대 감쇠의 절반 이상인 픽셀 수(반치 면적)
- 형상**: 장비별 평균 결함 패치와의 정규화 상관
- 위치**: 제품 영역의 외접 사각형 기준 정규화 좌표 (u, v), 제품 가장자리까지 거리
- 배경 비교**: 장비별 이미지 40장의 제품 픽셀 밝기 분포

데이터 다양성: GT 결함 1,147개의 크기·위치·밀도·대비 분포



형상: 결함 12×12px 감쇠율 맵 (진할수록 많이 가림). 모든 결함이 1~4px 점



조건	측정값 (5~95% 범위, 장비 3대)	제품 전체에서 가능한 범위	다양성
크기	반치 면적 1~7px (중앙 3~4px), 416 입력에서 한 번 1.0~2.6px	제품 크기 190~260px	❌ 한 가지 (1~4px 점)
위치	제품 안 고정된 4곳(시편 종류별 1곳 또는 3곳). 결함 위치 반경 10px이 제품 면적의 2~4%	제품 전체	❌ 4곳
위치 (가장 자리)	제품 가장자리에서 최소 36px	제품 면적의 53~68%가 가장자리 36px 안	❌ 가장자리 결함 0개
형상	모두 1~4px 점. 해상도 한계로 모양 구분 불가	—	❌ 한 가지
밀도 (감쇠)	감쇠율 0.41~0.60, OD 0.53~0.93 (변동계수 약 10%)	—	❌ 한 가지 재질·두께
개수	이미지당 1개 또는 3개 (시편 종류로 결정)	—	❌ 2가지
배경 (제품 두께)	결함 주변 밝기 1호기 105~118, 2호기 68~83, 3호기 86~97	제품 밝기 1호기 111~165, 2호기 76~136, 3호기 88~148	❌ 제품의 가장 어두운 부분(띠 끝)에만
대비 (CNR)	6~32. 장비 차이로만 변함(3호기 6~13)	—	△ 장비 3대만큼
잡음	장비별 고정(1호기·2호기 σ 1.5, 3호기 4.5)	—	△ 장비 3대만큼

- 모든 결함은 같은 시편의 같은 위치(어두운 띠 끝)에 있어서, 결함 주변 맥락까지 같습니다. 평균 패치(f11 첫 열)에 띠의 끝이 항상 같은 쪽에 보입니다.

- 장비 사이에서는 결함 대비 ÷ 배경 밝기가 0.34~0.36으로 일정합니다. 배경이 68→113으로 바뀌어도 같은 비율로 어두워지므로, **곰셈형 감쇠(Beer-Lambert)와 맞습니다**. 장비 안에서는 배경 범위가 좁아(±5) 따로 검증할 수 없습니다.

결론: 현재 데이터로는 모델의 조건별 미탐지 성능을 평가할 수 없습니다. 대비와 잡음은 장비 3대만큼만 변하고, 크기·위치·형상·밀도·배경은 사실상 한 가지입니다. 현재 test 점수 0.935는 **"처음 보는 날에 같은 시편을 찾는 능력"**입니다. 실험 ②에서 GT 없는 데이터가 효과가 없었던 이유도 같습니다. GT 없는 사진도 같은 시편을 찍은 것이라 새 조건을 더하지 못합니다.

3.7 과제 안내사항 준수

안내	적용
마커를 탐지 특징으로 사용 금지	모든 학습·평가 입력에서 마커를 지움. 마커는 지움 위치를 찾는 마스크로만 사용. 채택한 의사 라벨(T3)은 교사 모델의 검출에서 나오며 마커를 쓰지 않음
공식 정답 = TXT, 불일치 시 TXT 우선	공식 TXT를 수정 없이 복사해 사용(500개 바이트 대조). 마커는 있는데 TXT에 없는 결함 1건도 라벨을 추가하지 않음. 의사 라벨은 평가 정답에 쓰지 않음
전처리 허용, 방법·영향 명시	§ 3.2 (방법, 바뀐 픽셀 비율, 결함과의 거리, 흔적 검사)
외부 데이터: 사유·방법·출처 명시	COCO 사전학습 YOLOv3-SPP 가중치 (pjreddie.com/media/files/yolov3-spp.weights , md5 6c569c9ef748131c2d96b2deab446a5f). 외부 이미지·라벨은 사용하지 않음. 사유: 학습 결함 797개로 6,260만 파라미터 모델을 처음부터 학습하기엔 부족하고, 과제 제공 가중치는 평가 이미지가 섞여 초기값으로 부적합. 방법: backbone-neck 텐서 508/514개를 옮기고 출력 헤드는 새로 초기화한 뒤 전체 층을 미세조정. 제출 전 Darknet-COCO 라이선스 원문 확인 필요
외부 데이터 (새 베이스라인, § 3.8)	COCO 사전학습 YOLOv8s (github.com/ultralytics/assets/releases/download/v8.3.0/yolov8s.pt , md5 0a1d5d0619d5a24848a267ec1e3a3118, AGPL-3.0). COCO 사전학습 D-FINE-S (github.com/Peterande/storage/releases/download/dfinev1.0/dfine_s_coco.pth , md5 24db8615005ce1f8276cdcc37e6f948d, 코드 Apache-2.0). 사유·방법은 YOLOv3와 같음(출력 헤드를 1클래스로 새로 만들고 전체 미세조정). PIDray는 사전학습 조건 ③용으로 준비만 했고 아직 쓰지 않음(§ 6)
외부 데이터 (사전학습 비교, § 3.9)	PIDray (Wang et al., ICCV 2021 / Zhang et al., IJCV 2023, github.com/lutao2021/PIDray . 공식 Google Drive 라벨과 Hugging Face Voxel51/PIDray 영상 = 공식 test_easy 중 라벨 있는 9,482장). 사유: X선 도메인 사전학습이 2px 결함 검출에 도움이 되는지 확인. 방법: 흑백 변환 후 COCO → PIDray → KAMP 순서로 학습(§ 3.9). 결과: 이득이 없어 최종 모델에 쓰지 않음 . 라이선스가 학술 목적 한정이라 전달 패키지와 저장소에도 넣지 않음

3.8 새 베이스라인: YOLOv8s, D-FINE-S (COCO 사전학습)

질문: 최신 검출 모델로 바꾸면 성능과 실패 양상이 어떻게 달라지나? 두 모델을 학습한 뒤, 기존 실험(기본 평가, 마커 흔적 검사, 실패 조건, 합성 검증 V3·V4, 스트레스 곡선)을 **학습 없이 추론만으로** 다시 했습니다. 사전학습 3조건 비교(§ 6) 중 조건 ②(COCO)에 해당합니다.

설정 (`prep/run_nb2.sh`, `configs_nb2/dfine_s_kamp.yml`, `eval/nb2_eval.py`, `eval/nb2_models.py`, `prep/run_nb2_reruns.sh`, `eval/nb2_compare.py`)

항목	YOLOv8s	D-FINE-S
초기값	COCO 사전학습 (§ 3.7)	COCO 사전학습 (§ 3.7)

항목	YOLOv8s	D-FINE-S
데이터	전달 패키지와 같은 이미지(Telea 인페인팅)·분할·공식 TXT 라벨	같음
입력	640 (3호기 576×444가 줄어들지 않음)	640
학습	300 epoch, 배치 16. 기본 증강에서 확대·축소를 0.5 → 0.2로 줄임(0.5는 2px 결함을 1px로 뭉갬), 색상 증강 끄(흑백)	공식 custom 설정에서 RandomZoomOut 제거(최대 1/4로 줄여 결함이 사라짐), 배치 64 → 16(lr 1/2), 160 epoch(증강은 150에서 중지)
체크포인트 선택	val 0.1·AP50 + 0.9·AP50:95 최고 (epoch 125~135)	val AP50:95 최고 (epoch 58~64)
학습 시간 (RTX 4090 1장)	약 12분	약 29분
추론	신뢰도 ≥ 0.001 , NMS IoU 0.5 (YOLOv3와 같음)	신뢰도 ≥ 0.001 , NMS 없음(상위 300 쿼리)

- 평가는 YOLOv3와 같은 도구(공식 TXT, 같은 매칭·지표)를 씁니다.
- **체크포인트 선택 기준이 다릅니다.** YOLOv3는 val AP@0.5, 새 모델은 각 프레임워크 기본값(AP50:95 위주)으로 골랐습니다.
- **실패 조건과 합성 검증은 val·test 결함 350개만으로 했습니다.** § 3.5는 train 결함까지 교차 검증 교사로 채점했지만, 새 모델에는 교사가 없습니다. 아래 표의 YOLOv3 값도 같은 범위(베이스라인 seed 3개, val·test)로 다시 계산한 것이라 § 3.5· § 4.4의 값과 조금 다릅니다.

결과 1: 기본 평가 (seed 3개 평균 ± 표준편차)

모델	test AP@0.5	P / R@0.25	val AP@0.5	test 1호기	test 2호기	test 3호기	seed별 test AP
YOLOv3-SPP 416	0.935 ± 0.011	0.959 / 0.945	0.951 ± 0.015	0.983	0.933 ± 0.017	0.879 ± 0.011	0.943, 0.923, 0.940
YOLOv8s 640	0.958 ± 0.021	0.971 / 0.971	0.984 ± 0.007	0.979	0.942 ± 0.053	0.947 ± 0.008	0.952, 0.941, 0.982
D-FINE-S 640	0.942 ± 0.034	0.943 / 0.963	0.988 ± 0.007	0.985	0.938 ± 0.068	0.901 ± 0.014	0.958, 0.903, 0.964

- 평균은 YOLOv8s가 가장 높지만, 차이(+0.023, +0.007)가 seed 편차 안에 있습니다. 특히 2호기 test에서 seed 사이 편차가 큼(± 0.05~0.07).
- 가장 일관되게 오른 곳은 **3호기(0.879 → 0.947, YOLOv8s)**입니다. 640 입력에서 3호기 영상이 줄어들지 않기 때문으로 보이지만, 모델과 해상도를 함께 바꿔서 둘의 효과는 분리되지 않습니다.
- 세 모델 모두 중심거리 AP는 0.995입니다. 남은 차이는 박스 크기와 신뢰도 순위에서 나옵니다(§ 1.6).

결과 2: 실패 조건 (val·test 결함 350개 × seed 3)

	YOLOv3-SPP 416	YOLOv8s 640	D-FINE-S 640
놓침 (신뢰도 < 0.25), 전체	1.6%	0%	0%
놓침, 3호기 / 3호기 CNR 8~10	3.6% / 5.1%	0% / 0%	0% / 0%
찾은 결함 중 IoU < 0.5	3.5%	2.2%	2.8%
오검출 (신뢰도 ≥ 0.25 , 중심 기준, seed당)	0.3건	0건	0건
마커 흔적 검사: 가짜 링 450곳 반응 (신뢰도 ≥ 0.25 / ≥ 0.1)	0% / 0.22%	0% / 0.07%	0.07% / 0.15%

- 새 모델은 val·test 결함을 모두 신뢰도 0.25 이상으로 찾았습니다. YOLOv3의 유일한 약점이던 3호기 흐린 결함도 놓치지 않습니다.

- 마커를 지운 흔적에는 세 모델 모두 반응하지 않습니다(같은 자리의 원본과 차이 없음). D-FINE는 신뢰도 0.01 기준에서는 흔적 5.3%, 원본 3.7%로 둘 다 높습니다. 낮은 신뢰도 검출을 넓게 뿌리는 출력 특성으로 보입니다.

결과 3: 위치 사전 반응 (중요)

	YOLOv3-SPP 416	YOLOv8s 640	D-FINE-S 640
실제 결함을 지운 자리의 반응 (신뢰도 ≥ 0.25)	0.7%	21.1%	67.1%
같은 자리, 신뢰도 ≥ 0.1	10.6%	30.6%	78.1%
같은 지우기를 한 빈 자리(제품 안 3곳, 1,500곳)의 반응 (신뢰도 ≥ 0.1)	0%	0%	0%
스트레스 밀도 측 $k = 0.1$ (대비 1/10)에서 검출률	1.8%	31.6%	73.1%

- 결함을 지워도 새 모델은 그 자리에 결함이 있다고 답합니다. 같은 지우기를 다른 자리에 했을 때는 반응이 없으므로, **지운 흔적이 아니라 결함이 늘 있던 위치(띠 끝)에 반응**하는 것입니다. 결함 위치가 고정된 4곳뿐이라(§ 3.6) 위치만 보고도 답을 맞힐 수 있는 지름길이 있고, 새 모델은 YOLOv3(§ 4.3 부수 발견)보다 이를 훨씬 강하게 학습했습니다.
- 따라서 **새 모델의 높은 재현율에는 위치 기억이 섞여 있을 수 있습니다**. 현재 test는 같은 시편의 같은 위치라서, 결함을 보고 찾았는지 위치로 찾았는지 구분하지 못합니다.
- 스트레스 곡선(§ 4.4)은 새 모델에 대해 감도로 해석할 수 없습니다**. 검출률 50% 지점의 대비(전체)는 YOLOv3 10.3 → YOLOv8s 4.9 → D-FINE-S 1.9로 내려가지만, 결함이 거의 없을 때($k = 0.1$)도 검출률이 이미 32% / 73%입니다. 결함 감도가 아니라 위치 반응을 켜 것입니다. D-FINE의 1.9는 결함이 없는 자리에서 켜 대비(5~7)보다도 낮습니다. 비교 그림은 `eda/fig/n1_stress_models.png`, 값은 `eval/out_nb2/compare_stress.csv`에 있습니다.

결과 4: 합성 검증 V3 (실제 결함 vs 같은 자리 합성 결함, 결함별 신뢰도 상관)

합성	YOLOv3-SPP 416	YOLOv8s 640	D-FINE-S 640
옮겨 심기 (T_cross)	0.86	0.94	0.92
매개변수 합성 (R1_cal)	0.91	0.58	0.63

- 옮겨 심기는 새 모델에서도 실제 결함과 같은 반응을 냅니다. 매개변수 합성은 덜 일치합니다. 새 모델에서는 농침이 거의 없어 신뢰도가 1 근처에 몰리므로 상관이 불안정하지만, " 옮겨 심기는 조건부 통과, 매개변수 합성은 불통과"라는 § 4.3 판정과 같은 방향입니다(합성은 모두 평가 전용).

결론

- 새 모델은 실제 test에서 YOLOv3와 같거나 조금 낮습니다(평균 차이는 seed 편차 안). 3호기는 YOLOv8s에서 일관되게 좋아졌습니다.
- 세 모델 모두 val-test 결함을 사실상 다 찾아서, **현재 test로는 모델 사이의 감도 차이를 가릴 수 없습니다**.
- 새 모델은 **결함 위치를 지름길로 강하게 학습**했습니다. 그래서 다음 평가인 **위치 측 스트레스**(띠 끝이 아닌 자리에 결함을 옮겨 심기)가 모델 비교에서 가장 중요한 평가가 됩니다 → § 4.5에서 했고, 세 모델 모두 다른 자리 결함을 크게 놓쳤습니다. 학습에서도 옮겨 심기로 결함 위치를 다양하게 하는 것이 지름길을 줄일 후보입니다.

3.9 사전학습 비교: ① 없음 ② COCO ③ COCO → PIDray

질문: 결함 797개로 학습할 때 사전학습이 필요한가? X선 도메인 데이터(PIDray)로 한 번 더 사전학습하면 나아지나?

설정 (`prep/run_nb2.sh <모델> <gpu> <seed> scratch|coco|pidray`, `prep/run_pidray_pretrain.sh`, `configs_nb2/dfine_s_{pidray,kamp_scratch}.yaml`)

- KAMP 단계는 세 조건 모두 같습니다(§ 3.8의 해상도·증강·epoch·체크포인트 선택, seed 3개).
- ① 없음: 무작위 초기화. D-FINE는 ImageNet backbone 자동 다운로드도 끄(`HGNetv2: pretrained: False`).
- ③ PIDray 1단계: COCO 가중치에서 PIDray 흑백 9,482장(12종, train 8,534 / val 948)으로 학습. YOLOv8s 50 epoch(배치 32, PIDray val mAP50 0.963, mAP50:95 0.903), D-FINE-S 48 epoch(배치 32, val AP50:95 0.894). 2 단계에서 출력 헤드만 1클래스로 새로 만들고 나머지는 이어받음.

결과 (seed 3개 평균 ± 표준편차. 위치 측 = § 4.5, val·test 기증 결합)

모델	조건	실제 test AP@0.5	test 3호기	val AP@0.5	지운 자리 반응	다른 자리 k = 1
YOLOv8s	① 없음	0.927 ± 0.042	0.881	0.988	14.9%	29% ± 5
YOLOv8s	② COCO	0.958 ± 0.021	0.947	0.984	21.0%	42% ± 16
YOLOv8s	③ COCO → PIDray	0.947 ± 0.017	0.906	0.985	37.3%	53% ± 11
D-FINE-S	① 없음	0.908 ± 0.006	0.850	0.965	78.5%	80% ± 6
D-FINE-S	② COCO	0.942 ± 0.034	0.901	0.988	67.0%	83% ± 4
D-FINE-S	③ COCO → PIDray	0.943 ± 0.012	0.932	0.986	94.9%	84% ± 4

- 실제 test에서는 ② COCO가 가장 좋거나 같고, ③ PIDray의 추가 이득은 보이지 않습니다. ②와 ③의 차이는 seed 편차 안입니다. ① 없음은 두 모델 모두 가장 낮습니다(YOLOv8s 0.927, D-FINE-S 0.908). D-FINE-S ①은 신뢰도 0.25에서 정밀도도 낮습니다(test P 0.79~0.92).
- 위치 지름길은 사전학습 조건과 상관없이 생깁니다. 결합을 지운 자리 반응이 YOLOv8s ① 15% / ② 21% / ③ 37%, D-FINE-S ① 79% / ② 67% / ③ 95%입니다. YOLOv8s에서는 사전학습이 많을수록 커지지만 D-FINE-S에서는 일정한 순서가 없고, 사전학습이 없어도 강합니다. 지름길의 원인은 사전학습이 아니라 **결합 위치가 고정된 학습 데이터**입니다. 실제 데이터에는 다른 위치의 결합이 없고 합성 데이터는 학습에 쓰지 않으므로(§ 4 머리말), 지금 학습 방식으로는 꿀을 수단이 없습니다.
- PIDray는 물체가 크고(박스 중앙값 133px) 보안 검색 영상이라, 2px 결합 검출에는 도움이 제한적이라는 예상(§ 6)과 맞습니다. 라이선스(학술 목적 한정)를 고려하면 **최종 파이프라인에는 ② COCO를 권장**합니다.

4. 실험 ③: 조건 통제 합성 결합

§ 3.5· § 3.6의 결론: 실제 데이터의 약점은 "흐린 결합" 하나뿐이고, 나머지 조건은 측정할 수 없습니다. 그래서 아래 순서로 갑니다(failure-driven augmentation). 과제 요구사항 ②(조건별 성능 변화 분석)에 직접 답하는 구조입니다.

합성 모델(가설) → 합성 타당성 검증 → 통과? - 아니오 → 합성 방법 수정

↳ 예 → 스트레스 test → 실패 분석 (조건별 한계 보고)

원칙 (팀 결정, 2026-10-06): 합성 데이터는 학습에 쓰지 않고 test에만 씁니다. 모든 모델은 공식 TXT 라벨이 있는 실제 train 350장만으로 학습합니다. 합성은 실제 데이터로 썰 수 없는 조건(위치·크기·형상·재질·농도·잡음)에서 모델의 한계를 재는 데만 씁니다. 합성 타당성 검증(§ 4.3)은 "이 합성으로 썬 성능을 실제 결합에 대한 성능으로 읽어도 되는가"를 판정합니다.

4.1 참고한 방법

방법	내용	이 데이터에 적용
Threat Image Projection (TIP)	공항 X선 검색에서 쓰는 방식. 따로 찍은 위험물 X선 영상을 정상 가방 영상에 투과율을 곱해 겹침(Beer-Lambert). 합성만으로 학습한 모델이 실제 데이터 학습의 약 90% 성능(mAP 0.78 vs 0.88)을 낸 보고가 있음 [1]	곱셈 합성 원리를 씀. 따로 찍은 이물 영상은 없으므로 train 결합 797개의 실제 광학 밀도 맵을 이식 소스로 씀(시도 4). 실제 예가 없는 크기·형상은 매개변수로 생성
잘라 붙이기 (cut-paste)	따로 찍은 이물 X선 영상을 잘라 정상 포장식품 영상에 붙이되, 픽셀을 바꿔 넣지 않고 제품 밝기에 곱해서 붙임 [2]	실제 결합이 2×2px 점 하나뿐이라 모양을 다양하게 만들 수 없음 → 크기·모양 확장은 매개변수 생성으로
물리 시뮬레이션	3D 모델에서 투영 영상을 계산 [3]	제품 3D 정보와 장비 사양이 없어 적용 불가
생성 모델 (GAN·확산)	학습으로 이물 영상을 만들	학습할 이물 다양성이 없고 조건 통제가 어려워 쓰지 않음

4.2 합성 데이터를 만드는 방법

모든 합성은 같은 세 단계를 거칩니다. ① 실제 결함을 지운 배경을 만들고 ② 물체의 광학 밀도 맵을 곱셈으로 넣은 뒤 ③ 실제 결함과 비교해 검증합니다(§ 4.3). 방법은 넣는 물체의 출처에 따라 세 가지입니다.

방법	물체	쓰는 곳	검증 판정
옮겨 심기 (TIP)	실제 결함의 광학 밀도 맵을 다른 영상·자리로 옮김	위치 축(§ 4.5), 패키지 <code>pos_*</code>	조건부 통과
gVXR 물리 시뮬레이션	3D 형상 × 재질 × X선 스펙트럼으로 계산한 이물	크기·형상·재질 축(§ 4.6), 패키지 <code>gvxr_*</code>	평가 전용
매개변수 합성	사각 물체 ⊗ 가우시안 흐림	밀도·잡음 축(§ 4.4), 검증 비교용	불통과

모두 **평가(test) 전용**이며 학습에 쓰지 않습니다(팀 결정). 배경은 val·test 150장만 씁니다.

① 배경: 실제 결함 지우기 (`prep/synth/synth_core.py`, `build_replica.py`)

- 마커를 지운 영상에서 결함 중심에 이어진 "배경 - 대비/2보다 어두운" 픽셀에 2px을 더해 결함 영역으로 잡습니다. 이 영역을 마커 제거와 같은 Telea 인페인팅으로 지웁니다.
- 결과는 결함 없는 제품의 대응입니다(패키지 `erased`). 지운 자리에는 흔적이 있을 수 있지만, 같은 지우기를 다른 자리에 했을 때 모델은 반응하지 않았습니다(§ 3.8 V4).

② 넣는 원리: 곱셈 감쇠 (Beer-Lambert)

$$I_{\text{합성}}(x) = \text{배경}(x) \cdot \exp(-OD(x)) \quad OD = \text{광학 밀도 맵 (물체가 X선을 얼마나 막는가)}$$

- 곱셈이므로 같은 물체라도 밝은(얇은) 배경에서는 더 진하게, 어두운(두꺼운) 배경에서는 더 열게 보입니다. 실제 결함의 장비 간 차이가 이 성질과 맞습니다(§ 3.6).
- 결함이 픽셀 크기라서, 한 점에서 값을 찍지 않고 픽셀 면적 전체로 적분합니다.

옮겨 심기 (`build_replica.py`, `eval/synth/stress_pos.py`, `prep/synth/build_synth_test.py`)

- 실제 결함 1,147개마다 $OD = -\ln(\text{원본} / \text{결함 지운 영상})$ 으로 16×16px 광학 밀도 맵을 뽑습니다(`eval/synth/od_maps.npy`).
- 같은 장비의 train 결함 맵을 무작위로 골라 배울 $k(1 = \text{실제 농도}, 0.5 = \text{절반})$ 를 곱해 넣습니다.
- 자리는 두 가지입니다.
 - 원래 결함 자리(`canon`, 띠 끝)
 - 제품 안 무작위 자리 3곳(`random`, 4회): 원래 자리와 20px 이상, 서로 24px 이상, 제품 가장자리에서 2px 이상 떨어져. 자리와 기존 결함은 영상 이름으로 고정된 난수로 정해 언제 다시 만들어도 같습니다.
 - 장점은 실제 결함 그 자체라 가장 사실적이라는 점입니다. 한계는 크기·모양이 실제 시편 한 가지뿐이라는 점입니다.

gVXR 물리 시뮬레이션 (`prep/synth/gvxr_core.py`, `gvxr_calibrate.py`, `eval/synth/stress_gvxr.py`)

- 형상:** 구·정육면체·불규칙 조각·판·선을 무작위로 회전시켜, gVirtualXRay로 픽셀마다 X선이 지나는 두께를 계산합니다(8배 세분 후 픽셀 적분).
- 재질:** SUS304·Fe·Al·유리·돌·뼈·플라스틱의 에너지별 감쇠계수 $\mu(E)$ 를 씁니다.
- 장비 가정:** 70 kVp 텅스텐 스펙트럼, Al 2 mm 여과, 에너지 적분 검출기와 검출기 흐림을 가정합니다. 실제 장비 값은 데이터에 없습니다.
- 보정:** 실제 결함을 SUS304 구로 보고, 광학 밀도가 맞도록 장비별 픽셀 크기(약 0.1 mm/px)와 기준 지름(2.2~2.5px, 약 0.25 mm)을 정했습니다(§ 4.6 보정 표). 크기는 이 **기준 시편 대비 배수**로 표현합니다.
- 옮겨 심기와 같은 규칙의 무작위 자리 3곳 × 2회에 곱셈으로 넣습니다. - 장점은 실제에 없는 크기·형상·재질을 물리적으로 일관되게 만든다는 점입니다. 한계는 화소 수준에서 실제와 구별된다는 점과, mm 크기가 관전압 가정에 따라 약 2.5배 범위로 달라진다는 점입니다.

매개변수 합성 (`synth_core.py`): 수식으로 만든 결함입니다.

$I_{\text{합성}}(x) = (\text{배경}(x) + \text{잡음 보충}(x)) \cdot \exp(-OD0 \cdot \text{box}(x))$
 $\text{box} = \text{사각 물체(한 번 } w) \otimes \text{장비 흐림(가우시안 } \sigma), \text{ 픽셀 면적으로 적분 (물체 내부} = 1)$
 $OD0 = \text{물체 내부의 광학 밀도} \rightarrow \text{크기}(w) \cdot \text{흐림}(\sigma) \cdot \text{밀도}(OD0) \text{를 따로 조절}$

인페인팅으로 매끈해진 지운 영역에는 원래 수준의 잡음을 다시 채웁니다. 크기·흐림·밀도를 하나씩 바꿀 수 있어 § 4.4 밀도·잡음 축에 썼지만, 분류기가 실제와 구별해서 검증에서 탈락했습니다.

라벨과 평가 규칙

- 옮겨 심기: 장비별 실제 GT 박스 중앙값 크기(9 / 11 / 13px)
- gVXR: 이물 영역(광학 밀도 > 최대의 5%) 외접 사각형 + 2px (최소 = GT 중앙값)
- 정답 박스 크기 관례가 결과를 좌우하지 않도록 IoU를 쓰지 않습니다. 대신 **검출 중심이 물체 중심 8px 안**(gVXR는 이물 영역을 4px 넓힌 곳 안도 포함)이고 신뢰도 ≥ 0.25 이면 찾은 것으로 봅니다.
- 실제 예가 없는 조건(큰 이물, 비금속, 띠 끝이 아닌 자리)의 합성은 실제와 같은지 직접 검증할 수 없습니다. 그래서 결과는 **통제된 조건에서 모델이 가진 능력의 한계**로 해석하고, 현장 성능 추정으로 쓰지 않습니다.

4.3 합성 타당성 검증

방법: 복제 검사 (prep/synth/build_replica.py, eval/synth/validate_replica.py)

1. GT 결함 1,147개를 각각 Telea로 지우고, 지운 영역에 장비별 잡음을 다시 채웁니다.
2. 실제 결함에 합성 모델을 맞춰 $OD0 \cdot w \cdot \sigma$ 위치를 구합니다(관측 광학 밀도 $-\ln(\text{실제}/\text{지운 배경})$ 에 최소제곱).
3. **같은 자리에 합성 결함을 다시 넣고**, 실제 결함과 짝지어 비교합니다.
4. 모델 반응은 "그 사진을 학습에 쓰지 않은 모델"로 봅니다(val-test = 베이스라인 seed 3개, train = 교차 검증 교사).
5. 밝기 보정 계수는 train 결함으로만 정하고, 판정(V1·V2)은 val-test 결함 350개로 합니다.

통과 기준 (결과를 보기 전에 정함)

층	검사	통과 기준
V1 물리·화소	대비, CNR, 최대 광학 밀도, 반치 면적, 잡음 σ	실제 대비 표준화 평균차 $ SMD < 0.2$
V2 통계	반경 방향 밝기 단면	차이 < 결함 간 편차의 20%
V2 보조	실제 vs 합성 패치 구별 분류기 (장비·날짜 묶음 교차 검증)	$AUC \leq 0.60$. 단독으로 판정하지 않음
V3 모델 반응	놓침률, 신뢰도, 박스 중심 오차	놓침률 차 $\leq 2\%$, 기준 구간(3호기 CNR 8~10, 실제 놓침 10.4%) 에서 95% 구간이 겹침, 신뢰도 차 < 0.05, 중심 오차 차 < 0.5px
V4 빈 합성	결함 없는 곳 1,500곳을 지우고 잡음만 채움	반응률이 원본 대비 +0.5%p 이하

검사력 확인: 일부러 틀리게 만든 합성(흐림 없는 점, 잡음 미보충)은 분류기가 AUC 0.997~0.999로 구별했습니다. 실제 결함을 무작위로 둘로 나눈 음성 대조는 0.51이었습니다. 즉 이 검사는 틀린 합성을 잡아낼 힘이 있습니다.

결과

층	지표	시도 1 가우시안 점	시도 2 사각 물체 + 보정	시도 3 격자 정렬 + 보정	기준
V1	대비 SMD	+0.47 ✕	0.00 ✓	+0.03 ✓	< 0.2
V1	CNR SMD	+0.22 ✕	-0.06 ✓	+0.01 ✓	< 0.2
V1	최대 광학 밀도 SMD	+0.53 ✕	-0.01 ✓	+0.03 ✓	< 0.2
V1	반치 면적 SMD	+0.14 ✓	+0.27 ✕	+0.10 ✓	< 0.2
V1	잡음 σ SMD	+0.04 ✓	+0.04 ✓	+0.00 ✓	< 0.2

층	지표	시도 1 가우시안 점	시도 2 사각 물체 + 보정	시도 3 격자 정렬 + 보정	기준
V2	밝기 단면 차 (결함 간 편차 대비)	1.58 ✕	0.96 ✕	0.29 ✕	< 0.2
V2 보조	구별 AUC	0.97	0.97	1.00	≤ 0.60
V3	농침률 실제 → 합성	2.2% → 2.4%	2.2% → 3.2% ✓	2.2% → 4.9% ✕	차 ≤ 2%p
V3	기준 구간 농침률 실제 → 합성	10.4% → 5.8%	10.4% → 9.1% ✓ (16 → 14 / 154)	10.4% → 13.6% ✓ (16 → 21)	95% 구간 겹침
V3	신뢰도 차 / 상관	+0.008 / 0.94	-0.007 / 0.94 ✓	-0.022 / 0.90 ✓	< 0.05
V3	중심 오차 차	+0.02px	+0.02px ✓	+0.07px ✓	< 0.5px
V4	빈 합성 반응 (신뢰도 ≥ 0.1)	0% (1,500곳) ✓	0% ✓	0% ✓	+0.5%p 이하

- **시도 1 (가우시안 점)**: 실제보다 넓게 번지고 중심이 12% 더 어두워 V1에서 탈락했습니다.
- **시도 2 (사각 물체 $w \approx 1.7 \sim 1.9\text{px}$ ⊗ 흐림 $\sigma \approx 0.3\text{px}$, $OD0 \approx 0.7$, 밝기 보정 $\times 1.05 \sim 1.07$)**: 크기·밀도·대비와 모델 반응이 실제와 같습니다(V1 대부분, V3 전부 통과). 하지만 반치 면적이 약간 크고, 밝기 단면과 분류기(V2)에서 탈락했습니다. 합성 결함이 바로 옆 픽셀(반경 1~2px)까지 조금 더 번집니다(0.925 vs 실제 0.953).
- **시도 3 (결함 중심을 픽셀 경계에 고정)**: 실제 결함이 격자에 맞춘 2×2 블록처럼 보여서 시도했습니다. 화소 통계(V1)는 가장 좋아졌지만, 모양이 지나치게 규칙적이 되어 분류기가 거의 완벽히 구별하고(AUC 1.00), 모델 반응도 실제와 멀어졌습니다(농침 4.9%).
- 시도 2의 농침 차이(실제는 찾았는데 합성은 농침 29건 vs 반대 11건)는 통계적으로는 유의하지만, 크기가 1%p로 미리 정한 허용 범위(2%p) 안입니다.

분류기 AUC 해석의 주의점

- 복제 검사는 실제 결함을 먼저 지워야 합니다. 그런데 **결함이 없는 곳을 지우고 다시 채우기만 해도** 분류기가 AUC 0.89로 구별했습니다. 복제 검사의 AUC 0.97에는 이 "지우기 흔적"이 섞여 있습니다.
- 지우기 흔적을 맞춘 비교(주변은 똑같이 지우고 결함 픽셀만 실제/합성)에서는 0.89였습니다. 다만 이 비교도 실제 결함 픽셀과 채운 배경 사이에 이음매가 생겨 완전히 공정하지는 않습니다.
- 실제로 합성할 때는 지우지 않은 원래 배경에 넣으므로 지우기 흔적은 생기지 않습니다. 검출 모델은 지우기 흔적에 반응하지 않았습니다(V4 0%).

부수 발견: 실제 결함을 지운 자리에서도 모델이 신뢰도 0.1 이상으로 반응한 비율이 10.6%였습니다(0.25 이상은 0.65%). 결함이 없어도 "띠 끝" 위치 자체에 약하게 반응한다는 뜻입니다. 결함 위치가 늘 같아서 **위치 맥락을 일부 학습했음**을 보여 줍니다 (§ 3.6의 위치 편향).

1차 판정 (매개변수 합성): 합성 타당성 불성립 (V1·V3·V4 통과, V2 탈락).

- 시도 2는 **검출 모델 입장에서는 실제 결함과 같습니다(V3)**. 실제 관측 범위 안의 스트레스 평가에는 근거가 있습니다.
- 하지만 화소 수준에 구별 가능한 흔적이 남아 있어(V2), **학습에 넣으면 합성 흔적을 지름길로 배울 위험**이 있습니다.

시도 4: 옮겨 심기 (TIP 방식) — 교차 복제 검사

방법 (prep/synth/build_replica.py의 `T_self`, `T_cross`)

- train 결함마다 실제 광학 밀도 맵 $-\ln(\text{실제} / \text{지운 배경})$ 를 15×15px로 떼어 둡니다.
- **`T_cross` (옮겨 심기)**: 결함 A를 지운 자리에, **같은 장비·다른 날짜의 train 결함 B**의 광학 밀도 맵을 곁해 넣습니다. 그런 다음 실제 A와 비교합니다.
- **`T_self` (처리 대조)**: A를 지웠다가 **A 자신의 맵을 그대로** 다시 넣습니다. 결함은 진짜이고 지우기·잡음 보충 처리만 거친 것이므로, "처리만으로 생기는 차이"의 기준이 됩니다.


결과 (val-test 결함 350개, 굵게 = 판정 대상)

층	지표	처리 대조 T_self	시도 4 옮겨 심기 T_cross	시도 2 매개변수	기준
V1	대비 / CNR / 최대 광학 밀도 SMD	0.02 / 0.00 / 0.01	0.09 / 0.01 / 0.08 ✓	0.00 / -0.06 / -0.01	< 0.2
V1	반치 면적 SMD	0.06	0.22 (경계)	0.27 ✗	< 0.2
V1	잡음 σ SMD	0.01	0.01 ✓	0.04	< 0.2
V2	밝기 단면 차	0.49 ✗	0.69 ✗	0.96 ✗	< 0.2
V2 보 조	구별 AUC: 실제 원본 vs 각 방식	0.95	0.95	0.97	≤ 0.60
V2 보 조	구별 AUC: 처리 대조 T_self vs 각 방식 (gbm / logreg)	—	0.69 / 0.51	0.95 / 0.88	≤ 0.60
V3	농침률 실제 → 합성	2.2% → 2.7%	2.2% → 3.1% ✓	2.2% → 3.2%	차 $\leq 2\%p$
V3	기준 구간 농침 실제 → 합성	10.4% → 11.7%	10.4% → 8.4% ✓ (16 → 13 / 154)	10.4% → 9.1%	95% 구간 겹침
V3	신뢰도 차 / 상관	-0.001 / 0.98	-0.005 / 0.89 ✓	-0.007 / 0.94	차 < 0.05
V3	중심 오차 차	+0.01px	+0.10px ✓	+0.02px	< 0.5px
V4	빈 합성 반응	0%	0% ✓	0% ✓	+0.5%p 이하

해석

- **원래 V2 기준은 진짜 결함조차 통과하지 못합니다.** 처리 대조 T_self(결함은 진짜, 처리만 거침)도 실제 원본과 AUC 0.95, 밝기 단면 차 0.49로 탈락했습니다. 즉 실제 원본과 비교하는 V2는 합성의 차이가 아니라 **지우기·잡음 보충 처리의 흔적**을 주로 잡니다.
- 그래서 **같은 처리를 거친 진짜 결함(T_self)을 기준으로** 다시 비교했습니다.
 - 옮겨 심기는 AUC 0.69(gbm) / 0.51(logreg)로 거의 구별되지 않았습니다.
 - 매개변수 합성은 처리를 맞춰도 0.95 / 0.88로 여전히 구별됐습니다. 매개변수 합성의 흔적(바로 옆 픽셀로 더 번짐)은 처리 탓이 아니라 **모양 자체의 차이**입니다.
- 이 비교 기준은 결과를 본 뒤에 바꾼 것입니다(사후 변경). 그리고 gbm 0.69는 미리 정한 0.60보다 조금 높아서, **약한 흔적이 남아 있을 수 있습니다.**

합성 타당성 검증: 실제 결함을 지우고 같은 자리에 합성 결함을 다시 넣음 (24×24px)



같은 자리, 같은 회색조 범위로 본 실제 결함과 합성(test, 장비별 대비 중앙값에 가까운 결함). 눈으로는 셋 다 실제와 비슷하지만, 분류기(V2)는 매개변수 합성과 gVXR 구를 구별합니다.

2차 판정


합성 방법	판정	사용 범위
옮겨 심기	조건부 통과: V1·V3·V4 통과, 처리 대조 기준 V2 거의 통과(사후 기준)	위치·배경·잡음·밀도(배율)·개수 측의 스트레스 test (평가 전용, 팀 결정)
매개변수 합성	불통과 (처리를 맞춰도 V2 탈락)	평가 전용 . 실제 예가 없는 크기·형상 측은 이것만 가능하므로 "검증되지 않은 통제 조건"으로 표시

4.4 스트레스 곡선 v0 (실제 결함 자리, 학습 없음)

설정 (eval/synth/stress_v0.py, stress_v0_check.py, stress_v0_fig2.py)

- val·test 150장의 결함 350개를 베이스라인 seed 3개로 검출했습니다. 위치·배경은 실제 결함 자리 그대로 두고 **한 축만** 바꿨습니다.
- **밀도 축**: 결함을 지운 배경에 광학 밀도를 배율 $k = 0.1 \sim 1.3$ 로 다시 넣습니다. 옮겨 심기와 매개변수 합성 두 가지로 각각 했습니다.
- **잡음 축**: 실제 결함 영상 그대로에 흰 잡음 $\sigma = 1 \sim 12$ 를 더합니다(합성 결함 없음).
- 검출 = 결함 중심 8px 안에 신뢰도 0.25 이상의 검출이 있음. 결함 대비는 " $k \times (k = 1$ 일 때 전 대비)"인 명목값을 씁니다 (아래 측정 주의 참고).

스트레스 곡선 v0 (val·test 결합 350개 × 베이스라인 seed 3개, 학습 없음)



장비	실제 결함 대비 (하위 5% / 중 양값)	검출률 50% 대비	검출률 90% 대비	여유 (중앙값 ÷ 50% 지점)	실제 잡음 σ	검출률 50%가 되는 추가 잡음 σ
1호기	28 / 39	9.1	17.0	4.3배	1.1	12 초과 (σ 12에서 51%)
2호기	17 / 26	7.8	12.0	3.3배	1.7	7.4
3호기	27 / 33	16.2	24.9	2.1배	2.0	8.3

대비 단위는 회색조(0~255)입니다. 표의 값은 옮겨 심기 기준이며, 매개변수 합성과의 50% 지점 차이는 0.7 이하입니다. 실제 잡음 σ 는 이웃 화소 차로 추정했습니다.

발견

1. 두 합성기의 곡선이 일치합니다. 결론이 합성 방법에 좌우되지 않습니다.
2. 3호기는 같은 검출률을 내려면 결함이 약 두 배 진해야 합니다. 3호기 실제 결함의 하위 5%(대비 27)가 90% 지점(25) 바로 위에 있어서, 여유가 가장 작습니다. 실제 데이터에서 놓친 결함이 3호기 흐린 결함에 몰린 것 (§ 3.5)과 맞습니다.
 - 원인 가설(검증 안 됨): 3호기 영상(576×444)은 416으로 줄일 때 결함이 0.72배로 작아집니다. 그리고 잡음이 세 장비 중 가장 큼니다.
3. 잡음에는 여유가 큼니다. 실제 잡음(σ 1~2)에 σ 4를 더해도 재현율이 0.92 이상입니다.
4. 조건이 나빠져도 오검출은 늘지 않습니다. 모든 수준에서 이미지당 오검출이 0.002 이하였습니다. 조건 악화로 인한 실패는 농침입니다.

측정 주의: 대비 측과 잡음 측을 CNR 하나로 합치지 않은 이유

- 실제 영상에는 잡음이 거의 없습니다. 이웃 화소 차의 57~83%가 정확히 0입니다. 그래서 실제 영상에서 전 잡음 σ (CNR의 분모)는 측정 바닥값에 가깝습니다.
- 결함이 열으면 측정 대비가 부풀려집니다. 대비는 결함 근처 5×5 안의 최솟값으로 쥅니다. 그래서 결함이 열으면 배경 구조를 결함으로 잡습니다. 결함이 없는 자리에서도 대비가 5~7로 나왔습니다(그림 (a)의 점선).
- 그 결과, 측정 CNR로 그리면 "같은 CNR에서 대비 감소가 잡음 추가보다 훨씬 나쁘다"처럼 보였습니다(50% 지점 5.6 vs 3.2). 명목 대비로 바꾸면 차이가 줄었고, 남은 차이도 단위가 다른 두 양을 섞은 데서 옵니다.
- 열은 결함의 검출 한계를 정하는 것은 잡음이 아니라 배경 구조입니다. 그래서 두 측을 각자 단위(대비 / 추가 잡음 σ)로 보고합니다.
- § 3.5의 CNR은 실제 영상끼리의 순위로는 쓸 수 있지만, 절대값은 이 한계를 가집니다.

한계

- 밀도 측을 결함을 지운 배경 위에서 했습니다. 이 배경은 분류기가 구별할 수 있는 처리 흔적이 있습니다(검출 모델은 반응하지 않음, V4).

- 위치는 실제 결함 자리(띠 끝)로 고정했습니다. 모델이 이 위치에 약한 사전 반응을 가지므로(§ 4.3 부수 발견), **다른 위치에서는 곡선이 더 나뉠 수 있습니다.** 이것이 다음 스트레스 측입니다.
- 옮겨 심기는 $k = 1$ 에서만 검증했습니다. 배율을 바꾼 맵을 검증된 맵을 선형으로 조절한 것입니다.
- 이 곡선은 YOLOv3 기준입니다. 새 베이스라인(YOLOv8s, D-FINE-S)은 결함이 거의 없어도 이 위치에 반응해서($k = 0.1$ 에서 검출률 32% / 73%), 같은 방식으로는 감도를 썰 수 없습니다(§ 3.8).


4.5 위치 측 스트레스 (결함을 원래 자리가 아닌 곳에, 학습 없음)

질문: 결함이 늘 있던 자리(띠 끝)가 아닌 곳에 있으면 모델이 찾을까? § 3.8에서 새 모델이 결함을 지운 자리에도 반응해서, 위치를 빼고 감도를 따로 재야 했습니다.

설정 (eval/synth/stress_pos.py, stress_pos_summary.py)


- **배경:** 실제 결함을 지운 val·test 150장(data/synth_val/erased). 원래 결함 자리의 위치 반응이 섞이지 않게 했습니다.
- **결함:** 옮겨 심기(§ 4.3 조건부 통과). 같은 장비 train 결함의 실제 광학 밀도 맵을 무작위로 골라 배율 k 로 곱해 넣습니다.
- **자리:** 제품 안 무작위 자리 3곳 × 4회. 원래 결함 자리와 20px 이상, 서로 24px 이상, 제품 가장자리에서 2px 이상 떨어뜨렸습니다. 모델마다 장비 1·2·3호기 자리 684 / 516 / 600곳, 합계 1,800곳입니다(seed 3개 각각).
- **기준:** 같은 사진의 원래 결함 자리에 같은 방식으로 다시 심은 것(§ 4.3 T_cross와 같음).
- $k = 0$ (아무것도 심지 않음), 0.2, 0.35, 0.5, 0.75, 1(실제 농도). 검출 = 심은 결함 중심 8px 안에 신뢰도 0.25 이상.

위치 측 스트레스: 같은 실제 결함 맵을 띠 끝이 아닌 자리에 옮겨 심음 (확대 20×20px)



위치 측 합성 영상의 예. 원래 자리(주황)와 무작위 자리(파랑)에 같은 방식으로 실제 결함 맵을 옮겨 심었습니다. 무작위 자리 중에는 제품 가장자리도 있습니다.

위치 축 스트레스: 실선 = 제품 안 무작위 자리, 점선 = 원래 결함 자리



모델	무작위 자리, k = 1	원래 자리, k = 1	무작위 자리, k = 0.5	원래 자리, k = 0.5	원래 자리, k = 0 (빈 자리 반응)
YOLOv3-SPP 416	32.3% (seed 26~43%)	97.7%	11.6%	81.1%	0%
YOLOv8s 640	41.4% (seed 24~55%)	100%	13.6%	95.8%	21.0%
D-FINE-S 640	83.5% (seed 80~86%)	100%	47.9%	98.5%	67.0%

무작위 자리, k = 1에서 장비별 검출률:

모델	1호기	2호기	3호기
YOLOv3-SPP 416	23%	36%	40%
YOLOv8s 640	41%	51%	34%
D-FINE-S 640	93%	78%	78%

발견

- 세 모델 모두 결함을 "결함이 있던 자리"에서만 잘 찾습니다. 실제와 같은 농도의 결함을 다른 자리에 두면 YOLOv3는 3개 중 1개, YOLOv8s는 5개 중 2개만 찾습니다. 원래 자리에서는 98~100%입니다.
- 무작위 자리가 더 어려워서가 아닙니다. 무작위 자리의 결함 대비(중앙값 44 회색조)는 원래 자리(33)보다 오히려 높습니다. 배경이 더 밝아 같은 광학 밀도가 더 진하게 보이기 때문입니다(곱셈형 감쇠). 그리고 YOLOv3·YOLOv8s의 검출률은 대비가 높아져도 거의 오르지 않습니다(대비 20~30: 36% / 42%, 40~60: 32% / 41%).
- 보지 못하는 게 아니라 확신하지 못하는 것입니다. YOLOv3는 무작위 자리 결함의 99.8%에 신뢰도 0.01 이상, 82%에 0.1 이상으로 반응했습니다. 결함 모양은 보고 있지만, 띠 끝이라는 맥락이 없으면 신뢰도가 0.25를 넘지 못합니다. 판정 임계값(요구사항 ③)을 정할 때, 실제 test에서 고른 임계값이 다른 자리 이물에는 맞지 않는다는 뜻입니다.
- D-FINE-S가 위치 밖에서 가장 잘 찾습니다. 결함을 지운 자리에 가장 강하게 반응한 모델(67%)인데도, 다른 자리 결함을 가장 잘 찾았습니다(84%). "띠 끝이면 결함"이라는 사전 반응과 결함 자체를 보는 능력은 따로 움직입니다. 실제 test AP(§ 3.8)로는 이 차이가 전혀 보이지 않았습니다.
- 원래 자리 곡선은 위치 반응에 부풀려져 있습니다. 원래 자리에서는 농도를 절반으로 해도 81~99%를 찾지만, 다른 자리에서는 12~48%입니다. § 4.4의 스트레스 곡선(원래 자리)은 "띠 끝에 있는 결함"의 한계이지, 결함 일반의 한계가 아닙니다.

6. **배경이 어두울수록 잘 찾습니다.** 제품에서 가장 어두운 10% 자리(띠 끝과 비슷한 밝기)에서 YOLOv3 68% / YOLOv8s 73% / D-FINE-S 91%, 중간 밝기(25~50%)에서 20% / 27% / 77%입니다. 제품 가장자리 거리나 원래 자리까지 거리로는 일관된 차이가 없습니다.
7. **기증 결함을 바꿔도 같습니다.** train 결함 대신 학습에 쓰지 않은 val-test 결함(같은 장비, 다른 (장비, 날짜) 묶음)의 맵으로 심어도, 무작위 자리 $k = 1$ 검출률이 YOLOv3 32.6%, YOLOv8s 42.2%, D-FINE-S 83.2%로 같습니다.
8. **결함을 더 넣어도 오검출은 늘지 않습니다.** 심은 자리 밖의 신뢰도 0.25 이상 검출은 사진당 0.003건 이하입니다. 실패는 농침입니다.
9. **제품 가장자리 이물을 특히 놓칩니다.** 과제 설명이 걱정하는 '가장자리 이물'을 가장자리 거리별로 보면, 가장자리 0~8px 자리(모델당 255곳)에서 YOLOv3 27%, YOLOv8s 45%, D-FINE-S 70%만 찾습니다. 실제 데이터에는 가장자리 결함이 하나도 없어(§ 3.6) 합성으로만 짤 수 있습니다.

한계

- 옮겨 심기는 원래 결함 자리(띠 끝)에서만 검증했습니다(§ 4.3). 다른 배경에 넣은 결함이 그 배경의 실제 결함과 같은지는 실제 예가 없어 검증할 수 없습니다(§ 4.9). 다만 물리 모델(곱셈형 감쇠)과 결함 자체의 광학 밀도 맵은 실제와 같습니다.
- 배경은 결함을 지운 사진이라 원래 자리에는 지운 흔적이 있습니다. 같은 지우기를 다른 자리에 했을 때는 세 모델 모두 반응하지 않았습니다(§ 3.8 V4).

결론: 지금 모델들은 결함 감지기가 아니라 **"이 시편의 띠 끝 결함" 감지기**입니다. 실제 test 점수(0.935~0.958)는 이 능력을 재며, 다른 위치의 이물에 대해서는 크게 과대평가합니다. 합성 데이터는 학습에 쓰지 않으므로, 이 결과는 운영 판정(§ 5)과 한계(§ 7)에 그대로 반영합니다.

4.6 크기·형상·재질 측: gVXR 물리 합성 (학습 없음)

질문: 실제 데이터에 한 가지씩밖에 없는 이물의 크기·형상·재질(§ 3.6)이 바뀌면 모델이 찾을까? 과제 설명의 "작은 이물질" 조건도 여기서 짭니다.

합성기 (prep/synth/gvxr_core.py, gVirtualXRay 2.1.0)

- 실제 KAMP 배경(결함을 지운 val-test 150장)은 그대로 두고, 이물 부분만 시뮬레이션해서 곱셈으로 넣습니다($I = I_{\text{배경}} \cdot \exp(-OD)$).
- **gVXR**이 3D 형상의 투영 두께와 재질별 감쇠계수 $\mu(E)$ 를 계산합니다. 형상은 구, 정육면체, 무작위 볼록 조각, 판, 선입니다. 재질은 원소·화합물·혼합물 데이터베이스에서 가져옵니다. 다색 스펙트럼 투과율, 검출기 흐림(투과율에 가우시안), 픽셀 적분은 numpy로 계산합니다.
- **장비 가정:** 70 kVp 텅스텐 Kramers 스펙트럼, Al 2 mm 여과, 에너지 적분 검출기, 평행빔. 실제 장비 값(관전압, 필터, 픽셀 크기, 검출기)은 데이터에 없습니다. 제품이 미리 거른 스펙트럼 변화(빔 경화)는 무시했습니다.
- **재질:** SUS304, Fe, Al, 유리(SiO_2 2.5), 돌(CaCO_3 2.71), 뼈(ICRU 피질골 1.92), 플라스틱(폴리프로필렌 0.9).
- 설치: 프로젝트 .venv 에만 설치했습니다. 시스템에 없는 xcb 라이브러리 4개는 Ubuntu 패키지에서 추출해 third_party/gvxr_libs/ 에 두고 실행 중에 불러옵니다.

보정 (prep/synth/gvxr_calibrate.py, train 결함만): 실제 결함(시편)을 **SUS304** 구로 보고, 장비별로 구 지름 $D(\text{px})$ 와 픽셀 크기 $p(\text{mm/px})$ 를 정했습니다. 맞추는 값은 적분 광학 밀도와 최대 광학 밀도(맞춤 오차 2% 안팎)입니다.

가정	기준 구 지름 D	픽셀 크기 p	기준 구 지름 (mm)
SUS304, 70 kVp (기본)	2.2 / 2.3 / 2.5 px (1·2·3호기)	0.11 / 0.11 / 0.10 mm	약 0.25 mm
SUS304, 50 / 90 kVp	2.2~2.6 px	0.05~0.07 / 0.14~0.17 mm	0.13~0.14 / 0.35~0.38 mm
Fe, 70 kVp	같음	같음	같음
유리, 70 kVp	2.3~2.5 px	2.5~2.7 mm	약 6 mm (화면 폭 약 88 cm → 비현실적)

- **px 단위 크기는 가정과 무관하게 안정적이지만, mm 단위는 관전압 가정에 따라 약 2.5배 바뀝니다.** 그래서 크기 측은 **기준 시편 대비 배수로** 보고합니다. mm는 기본 가정의 참고값입니다. 시편을 유리로 보면 픽셀 크기가 비현실적이 되므로, 금속 시편 가정이 타당합니다.

합성 타당성 검증 (prep/synth/build_gvxr_replica.py, § 4.3과 같은 V1~V4, val-test 결함): 실제 결함을 지운 자리에 gVXR 구를 다시 넣었습니다. G_fit은 결함마다 적분 광학 밀도에 맞춘 지름이고, G_gen은 장비별 보정값만 쓴 것입니다.


검사	옳겨 심기 T_cross	매개변수 R1_cal	gVXR G_fit	gVXR G_gen
V1 최대 광학 밀도 / 반치 면적 SMD (기준 < 0.2)	0.08 / 0.22	-0.01 / 0.27	-0.21 / 0.20	-0.38 / 0.13
V2 구별 분류기 AUC, 같은 처리 대비 (기준 ≤ 0.60)	0.69	0.95	0.98	0.98
V3 결함별 신뢰도 상관: YOLOv3 / YOLOv8s	0.89 / 0.94	0.94 / 0.58	0.96 / 0.97	0.95 / 0.98
V3 농침률 차이 (기준 ≤ 2%p)	통과	통과	통과 (0)	통과 (0)

- 검출 모델에게는 **gVXR 구가 실제 결함과 가장 비슷합니다**. 결함별 신뢰도 상관이 두 모델 모두 0.95 이상입니다. 매개변수 합성은 새 모델에서 0.58로 떨어졌습니다.
- 화소 수준에서는 분류기가 구별합니다(AUC 0.98)**. 미리 정한 기준에 따라 **평가 전용**입니다(매개변수 합성과 같은 판정). 실제에 없는 크기·형상·재질은 어떤 합성기로도 검증할 수 없으므로 "통제 조건"으로만 해석합니다 (§ 4.9).

스트레스 설정 (eval/synth/stress_gvxr.py): 제품 안 무작위 자리 (§ 4.5와 같은 규칙) 이미지당 3곳 × 2회, 모델마다 조건당 900곳(seed 3개 각각). 한 번에 한 축만 바꿉니다.

- 크기: SUS304 구, 지름 = 기준 × 0.5~5
- 형상: SUS304, **부피 = 기준 구**, 무작위 회전. 구 / 정육면체 / 불규칙 조각 / 판(두께 = 한 변의 1/5) / 선(길이 = 지름의 10배, 20배)
- 재질: 구, 지름 = 기준 × 1, 2, 4, 8

gVXR 크기·형상·재질 측: 같은 자리에 조건만 바꿔 넣음 (test 002_20200714_083054(2), 1호기, 32×32px, 회색조 0~159 고정)
 실제 결함의 대비는 17~59. 대비 10 미만(회색 글씨)은 잡음·배경 구조 수준



gVXR 측 합성 영상의 예(같은 자리, 같은 회색조 범위). 같은 크기의 비금속(× 1)과 플라스틱은 대비가 잡음 수준이라 눈으로도 보이지 않습니다.

찾음은 신뢰도 0.25 이상인 검출 중심이 이물 중심 8px 안이거나, 이물 영역을 4px 넓힌 곳 안에 있는 경우입니다(긴 선 고려).

결과 (검출률, 신뢰도 ≥ 0.25 . 대비 = 배경 $\times (1 - e^{-OD_{\text{최대}}})$, 회색조. 면적 = 반치 면적 px. 실제 결함은 대비 17~59, 면적 1~7)

조건	대비 / 면적	YOLOv3	YOLOv8s ②	D-FINE-S ②
크기 × 0.5 (약 0.13 mm)	16 / 2	0%	0%	2%
크기 × 0.75	37 / 2	11%	13%	44%
크기 × 1 (기준 시편)	57 / 3	29%	41%	81%
크기 × 2	91 / 11	57%	95%	97%
크기 × 3	103 / 26	43%	75%	89%
크기 × 5 (약 1.3 mm)	114 / 80	11%	65%	42%
크기 × 8 (약 2 mm, 재질 측)	120 / 217	0%	31%	4%
형상: 구 / 정육면체 / 조각 / 판	43~57 / 3~5	22~30%	31~41%	67~81%
형상: 선 (길이 10배)	28 / 9	6%	12%	17%
형상: 선 (길이 20배)	20 / 15	0%	4%	4%
Al × 2 / × 4 / × 8	13 / 25 / 43	0~1%	1%	8 / 18 / 3%
유리 × 2 / × 4 / × 8	10 / 19 / 34	0%	0%	1 / 10 / 2%
돌 × 2 / × 4 / × 8	20 / 36 / 57	0~5%	4~8%	29 / 33 / 4%
뼈 × 2 / × 4 / × 8	11 / 21 / 37	0~1%	0~1%	3 / 12 / 3%
플라스틱 × 1~8	1~6	0%	0%	0%
같은 크기(× 1)의 Al / 유리 / 돌 / 뼈	4~8 / 3	0%	0%	0%

발견

- 가장 큰 사각지대는 "크고 열은" 이물입니다.** 기준보다 큰 이물은 대비가 충분한데도(×5 SUS: 대비 114, 면적 80px) 놓칩니다. 실제 결함과 대비가 같은 크기 × 8 유리(대비 34, 면적 202px)는 모든 모델이 3% 이하로 찾습니다. 모델은 "2~3px 점"을 결함으로 배웠고, **덩어리**는 결함으로 보지 않습니다. 결함 크기가 한 가지뿐인 학습 데이터(§ 3.6)의 직접적인 결과입니다.
- 같은 크기라면 금속만 보입니다.** 기준 시편과 같은 크기의 Al·유리·돌·뼈는 대비가 4~8로, 잡음과 배경 구조 수준입니다 (§ 4.4: 결함 없는 자리에서도 측정 대비 5~7). 비금속 이물은 2~4배 이상 커야 보이는데, 그 크기에서는 1번의 사각지대에 걸립니다. 플라스틱은 8배(약 2 mm)에서도 대비 6이라 물리적으로 보이지 않습니다. 이 영역은 모델이 아니라 **촬영 조건의 한계**입니다.
- 작은 쪽도 사각지대입니다.** 기준의 절반(약 0.13 mm, 대비 16)에서 0~2%, 3/4 크기(대비 37)에서 11~44%입니다. 같은 크기라도 띠 끝이 아닌 무작위 자리라서 위치 지름길 (§ 4.5)이 함께 작용합니다.
- 형상:** 부피가 같으면 구·정육면체·불규칙 조각·판은 큰 차이가 없습니다(YOLOv8s 31~41%, D-FINE-S 67~81%). **가늘고 긴 선**은 대비가 낮아지면서(28, 20) 검출률도 떨어집니다. 길이 10배에서 6~17%, 20배에서 0~4%입니다.
- 모델마다 강한 쪽이 다릅니다.** D-FINE-S ②는 기준 이하 크기와 비금속에서 낮고(× 0.75 44%, × 1 81%, 돌 × 4 33%; YOLOv8s ② 13%, 41%, 8% 이하), YOLOv8s ②는 큰 이물에서 낮습니다(× 5 65%, × 8 31%; D-FINE-S ② 42%, 4%). D-FINE-S ②는 위치 지름길이 강해서 운영 판정에는 맞지 않습니다 (§ 5). **실제 test만으로 모델을 고르면 이 차이가 보이지 않습니다.**
- 결과가 기준 시편 배수로 표현되므로, mm 환산은 관전압 가정에 따라 약 2.5배 범위가 있습니다.** 재질 사이의 비율도 스펙트럼에 따라 바뀝니다. 실제 장비 사양(관전압, 필터, 픽셀 크기)을 알면 다시 계산해야 합니다.

결론: 지금 모델들은 "띠 끝에 있는, 시편과 비슷한 크기의 금속 점"에 특화돼 있습니다. 과제 설명이 우려하는 "작은 이물"과 "가장자리 이물" (§ 4.5), 그리고 **기준보다 큰 이물·가는 선·비금속 이물**이 모두 사각지대입니다. 합성 데이터는 학습에 쓰지 않으므로(팀 결정) 이 사각지대는 조건별 한계로 보고합니다. 메우려면 실제로 다양한 이물(크기·재질·위치)을 넣어 촬영한 데이터가 필요합니다.

4.7 조건 측 (한 번에 하나만 바꾸고, 나머지는 실제 결함의 중앙값으로 고정)

실제 관측 범위와 관측되지 않은 스트레스 범위를 구분합니다. 스트레스 범위의 값은 과제 설명에 이물 크기·종류 범위가 없어서 정한 **통제 조건**이며, 실제 이물의 범위라고 주장하지 않습니다.

측	실제 관측 범위	스트레스 범위 (관측 안 됨)
크기 (물체 한 변 w)	1.7~1.9px (반치 면적 1~7px)	1px 미만, 3·5·8·12px
형상	점	타원(가로세로 비 2~6), 선(길이 5~30px, 폭 1~2px), 불규칙 덩어리. 실제 식품 이물 형상이라는 근거가 없으므로 "형상 일반화를 보는 통제 조건" 으로만 해석
밀도 (OD0)	0.6~0.8	0.05, 0.1, 0.2, 0.35, 1.0, 1.5
배경 (제품 밝기)	제품에서 가장 어두운 5~10%	제품 밝기 25·50·75·95% 지점
잡음 / CNR	CNR 6~32 (3호기 6~13). 결함 대비 17~59 회색조	1·2호기에 잡음을 더해 3호기 수준 이하로. 실제 약점(3호기 흐린 결함)이 기준점 . CNR은 측간 비교에 쓰지 않음(§ 4.4 측정 주의)
위치	고정된 4곳, 가장자리에서 36px 이상	제품 내부 격자 전체. 가장자리 0~36px 띠 포함
개수	1 또는 3	1~5

4.8 스트레스 test 운영 원칙

항목	내용
스트레스 test 구성	val 66장 / test 84장에만 합성 (train 사진 사용 안 함). 측·수준마다 결함 약 300개 이상. 완료 : 밀도·잡음(§ 4.4), 위치(§ 4.5), 크기·형상·재질(§ 4.6). 남은 측 : 배경(제품 밝기) 단독 측, 개수
실패 분석	조건별 재현율·정밀도·위치 오차·놓침률 곡선. 관측 범위와 스트레스 범위를 그림에서 구분
학습 사용	하지 않음 (팀 결정, 2026-10-06). 합성은 조건별 성능 측정에만 씀

- 임계값 등 방법 선택은 실제 val(과 스트레스 val)로만 합니다. 실제 test와 스트레스 test는 최종 보고에만 씁니다.
- 합성 데이터는 대회 데이터로 만들므로 외부 데이터가 아닙니다. 다만 전처리처럼 방법과 영향을 결과보고서에 명시합니다.

4.9 한계

- 실제 생산 라인의 이물이 어떤 재질·모양인지 모릅니다. 스트레스 결과는 "이런 조건이면 모델이 이렇게 된다"는 **능력의 한계**이지, 현장 성능 추정이 아닙니다.
- 복제 검사는 실제 결함이 있는 조건(띠 끝, 점 모양)에서만 합성을 검증할 수 있습니다. 관측 범위 밖(큰 크기, 다른 배경, 다른 형상)의 합성은 같은 물리 모델을 쓴다는 것 외에는 검증할 방법이 없습니다.

[1] Bhowmik et al., "The Good, the Bad and the Ugly: Evaluating CNNs for Prohibited Item Detection Using Real and Synthetically Composited X-ray Imagery", 2019. <https://arxiv.org/abs/1909.11508> [2] "Real-Time Anomaly Detection in Packaged Food X-Ray Images Using Supervised Learning", CMC 67(2). <https://www.techscience.com/cmc/v67n2/41335> [3] "CT-based data generation for foreign object detection on a single X-ray projection", Scientific Reports, 2023. <https://www.nature.com/articles/s41598-023-29079-w>

5. 판정 기준 제안 (요구사항 ③)

질문: 검출 결과를 현장에서 어떻게 쓸까? 어디까지 자동으로 불량 판정하고, 어디부터 사람이 다시 볼까? 제품 영역 밖 검출을 버리면 나아질까?

규칙 (eval/decision/collect_dets.py, thresholds.py)

- 검출마다 신뢰도가 **T_high** 이상이면 자동 불량, **T_low** 이상 **T_high** 미만이면 재검사, **T_low** 미만이면 버립니다. 사진의 판정은 그 사진 검출 중 가장 높은 등급입니다.

- 위치는 결함 중심과 검출 중심의 거리 $\leq 8\text{px}$ 로 판정합니다. 정답 박스 크기가 들쭉날쭉해서(§ 1.6) IoU 대신 씁니다. "어디에 이물이 있는가"를 표시하는 목적에는 충분합니다.
- 임계값은 seed마다 val로만 정합니다.
 - **T_high** = val의 '결함 아닌 검출' 중 최고 신뢰도 바로 위. 결함 아닌 검출은 실제 영상에서 짝이 없는 검출과, 결함을 지운 영상(결함 없는 제품 대응)의 모든 검출입니다. val에서 자동 불량 오판이 0이 되는 가장 낮은 값(정책 R).
 - **T_low** = val 실제 결함을 하나도 놓치지 않는 가장 높은 값(정책 R).
 - 정책 P는 다른 자리 결함(위치 축 val, $k = 1$)도 99% 잡도록 T_low를 더 낮춘 것입니다.
- test 평가 항목은 다섯 가지입니다.
 - 실제 결함 206개
 - 실제 영상 84장의 오검출
 - 결함을 지운 test 84장(결함 없는 제품 대응)
 - 위치 축 test 다른 자리 결함($k = 1, 0.5$)
 - GT 없는 2,020장의 사진 판정 비율(재검사 부담)
- **결함 없는 정상 영상이 데이터에 없어서**, 결함을 지운 영상을 대신 씁니다. 지운 자리에는 흔적이 있습니다. 다만 같은 지우기를 다른 자리에 했을 때 모델이 반응하지 않았으므로(§ 3.8 V4), 흔적 자체가 오판을 만들지는 않습니다.

대상 모델: 합성 데이터는 학습에 쓰지 않으므로(팀 결정, § 4 머리말), 실제 train만으로 학습한 YOLOv8s ② COCO와 D-FINE-S ② COCO(§ 3.8)를 비교합니다. 위치 축(다른 자리 결함)과 결함 없는 제품은 평가 전용 합성(§ 4.5, 결함 지운 영상)으로 씁니다.

결과 (정책 R, 제품 영역 후처리 적용, seed 3개 평균. eval/decision/summary.csv)

모델	T_low ~ T_high (seed 범위)	test 결함: 자동 / 재검사 / 놓침	test 오검출 (사진당, 자동)	결함 없는 제품: 자동 불량 / 재검사	다른 자리 k = 1: 자동 / 놓침	다른 자리 k = 0.5: 자동 / 놓침	GT 없는 2,020장: 재검사
YOLOv8s ② COCO	0.56~0.65 ~ 0.60~0.68	79.4% / 19.7% / 0.8%	0	2.8% / 5.6%	8.8% / 83.6%	1.9% / 95.9%	5.2%
D-FINE-S ② COCO	0.57~0.67 ~ 0.74~0.78	28.3% / 71.7% / 0%	0	2.0% / 51.2%	0.1% / 59.9%	0% / 86.8%	45.9%

정책 P(다른 자리 결함 99%를 잡도록 T_low를 낮춤), YOLOv8s ②: T_low가 0.001까지 내려가 test 결함 놓침 0, 그러나 결함 없는 제품 재검사 79.8%, 다른 자리 k = 1 놓침 18.0%(재검사 73.1%), GT 없는 영상 재검사 6.3%.

발견

1. **T_high는 결함을 지운 원래 자리의 반응이 정합니다.** YOLOv8s ② seed 3개 모두, val에서 가장 높은 '결함 아닌 검출'은 실제 영상의 오검출이 아니라 결함을 지운 영상의 띠 끝 자리(신뢰도 0.60~0.68)였습니다. 위치 지름길(§ 3.8, § 4.5)이 임계값을 끌어올리는 셈입니다. 그래서 T_low와 T_high 사이가 좁고(0.04~0.09), 실제 결함의 약 20%가 재검사로 갑니다.
2. **다른 자리 결함은 판정 기준으로 메울 수 없습니다.** YOLOv8s ②는 실제 농도의 다른 자리 결함 84%를 놓칩니다. 다른 자리 결함은 T_low보다 훨씬 낮은 신뢰도로 나오기 때문입니다. 정책 P로 T_low를 0.001까지 내리면 결함 없는 제품의 80%가 재검사로 가는데도 다른 자리 결함의 18%는 여전히 놓칩니다. 합성 학습을 하지 않으므로 이 한계는 남습니다(§ 7).
3. **D-FINE-S ②는 운영에 맞지 않습니다.** 원래 자리 반응이 강해서(67%) T_high가 0.74~0.78로 높아집니다. 실제 결함의 72%가 재검사로 가고, GT 없는 영상의 46%가 재검사입니다.
4. **실제 결함 기준으로는 쓸 만합니다.** YOLOv8s ②는 test 실제 결함 206개 중 79%를 자동 불량, 20%를 재검사로 보내고 놓침은 0.8%(seed당 1~2개)입니다. 실제 영상의 자동 불량 오검출은 0입니다. GT 없는 2,020장은 88.7%가 자동 불량, 5.2%가 재검사, 6.1%가 통과입니다. 이 데이터는 결함 시편을 반복 촬영한 영상이므로(§ 1.7) 대부분 자동 불량에 맞는 판정입니다.
5. **남는 위험은 결함 없는 제품의 자동 불량 오판(2.8%, 84장 중 seed당 약 2.3장)입니다.** 모두 결함을 지운 원래 자리에 대한 반응입니다. 결함 지운 영상은 정상품의 대응이고 지운 자리에 흔적이 있으므로, 실제 정상품에서 이 비율이 같을지는 알 수 없습니다(같은 지우기를 다른 자리에 했을 때는 반응하지 않음, § 3.8 V4). 운영에서는 T_high를 조금 높여 재검사로 돌리는 쪽이 안전합니다.

6. **제품 영역 후처리는 효과가 없습니다.** 정책 R의 임계값(T_{low} 0.56 이상)에서는 제품 밖 검출이 남지 않아 판정이 바뀌지 않습니다(정책 P에서만 실제 영상 재검사 오검출이 사진당 0.55 → 0.20건으로 줄). 비용이 없으니 파이프라인에는 넣습니다.
7. **임계값이 seed마다 다릅니다**(T_{high} 0.60~0.68). val 결함 144개, 결함 없는 영상 66장으로 정하기 때문입니다. 최종 모델 하나를 고른 뒤 그 모델의 val로 다시 정해야 하고, 숫자 자체보다 "val에서 오판 0이 되는 가장 낮은 값"이라는 **정하는 방법**을 제안합니다.

제안

- 모델: **YOLOv8s ② COCO** (실제 train만으로 학습, 합성 없음), 입력 640, 제품 영역 밖 검출 제거.
- 판정: T_{high} = val에서 결함 아닌 검출(결함 지운 영상 포함)의 최고 신뢰도 바로 위, T_{low} = val 실제 결함 최저 신뢰도 (정책 R). seed 3개에서 T_{low} 0.56~0.65, T_{high} 0.60~0.68.
- 기대 성능(test, seed 평균): 실제 결함 79% 자동 · 20% 재검사 · 놓침 0.8%, 실제 영상 자동 오검출 0, 결함 없는 제품 자동 불량 오판 2.8% · 재검사 5.6%, GT 없는 영상 재검사 5.2%.
- **한계 (합성 test로 댄 것):** 띠 끝이 아닌 자리의 결함은 실제 농도에서도 84%를 놓칩니다(§ 4.5). 가장자리·작은·큰·비금속 이물도 대부분 놓칩니다(§ 4.5, § 4.6). 이 판정 기준의 성능은 "**정해진 시편 자리의 금속 점**"에 대한 것이며, 생산 라인의 임의 위치 이물에 대한 성능이 아닙니다. 결함 없는 제품 수치는 결함을 지운 영상으로 댄 값이라 실제 정상품으로 다시 확인해야 합니다.

최종 모델 확정

- seed 3개 중 **val AP가 가장 높은 seed 1**을 골랐습니다. 선택에는 val만 쓰고 test는 보지 않았습니다. 가중치는 `runs/nb2/yolov8s_s1/weights/best.pt` (md5 85cfdfb74bbc361eb135d28ca120517e)입니다.

seed	val AP@0.5	test AP@0.5	비고
0	0.979	0.952	
1	0.992	0.941	선택 (val 최고)
2	0.981	0.982	

- **확정 임계값**(정책 R, 제품 영역 후처리, seed 1의 val로 계산): **$T_{low} = 0.648$, $T_{high} = 0.684$**
- **test 결과:**
 - 실제 결함 206개: 76.7% 자동 불량, 20.9% 재검사, **2.4% 놓침(5개)**
 - 실제 영상 자동 오검출 0
 - 결함 없는 제품(결함 지운 영상) 84장: 자동 불량 오판 3.6%(3장), 재검사 2.4%
 - GT 없는 2,020장: 재검사 3.2%
 - 다른 자리 결함($k = 1$): 82% 놓침
- 고른 seed의 test AP가 셋 중 가장 낮고, 놓침도 seed 평균(0.8%)보다 많습니다. T_{low} 가 val 결함 144개 중 최저 신뢰도 하나로 정해지기 때문에 seed마다 흔들립니다. test를 보고 seed나 임계값을 다시 고르면 test가 선택에 쓰이므로 바꾸지 않았습니다. 운영에서 놓침을 더 줄이려면, " T_{low} 를 val 최저 신뢰도에서 일정 폭 낮춘다" 같은 규칙을 **val만으로 미리 정해** 적용해야 합니다.

6. 최종 선택

요인	선택 / 상태
① 마커 처리	Telea 인페인팅 (반경 3) . 7가지 방식 교차표와 흔적 검사로 확인

요인	선택 / 상태
② GT 없는 데이터	라벨 방법은 교사 + 구조 필터(T3) 가 가장 정확하지만, 학습 효과가 없어 학습에 쓰지 않음 (검증·이상 입력 점검용)
③ 데이터 다양성	다양성 부족을 정량화함 (§ 3.6). 실제 약점은 3호기 흐린 결함 (§ 3.5). 합성 데이터는 평가(test) 전용 (팀 결정 2026-10-06), 학습에 쓰지 않음. 합성 검증 (§ 4.3): 옮겨 심기 조건부 통과, 매개변수 합성 불통과, gVXR (§ 4.6) 모델 반응은 가장 비슷하나 분류기가 구별. 스트레스 test 완료: 밀도·잡음 (§ 4.4, 3호기는 결함 대비가 약 두 배 필요), 위치 (§ 4.5, 다른 자리 결함 YOLOv8s 41%만 찾음), 크기·형상·재질 (§ 4.6, 작은·큰·선·비금속 이물 사각지대). 남은 축: 배경 단독, 개수
④ 모델	새 베이스라인: YOLOv8s, D-FINE-S (2026-10-01 결정). YOLOv3-SPP 결과는 제공 코드 기준 참고값으로 유지. 해상도 640 권장(3호기 영상이 축소되지 않음). 사전학습 3조건 비교 : ① 없음 ② COCO ③ COCO → PIDray(X선 도메인) → KAMP. PIDray 준비 완료(아래). 조건 ② 결과 § 3.8, 세 조건 비교 § 3.9 : 실제 test는 ② COCO가 가장 좋거나 같고 PIDray 추가 이득 없음 → ② COCO 권장
외부 데이터	최종 모델은 COCO 사전학습 가중치만 씁니다 (§ 3.7). PIDray (공식 test_easy 중 라벨 있는 9,482장, 흑백 변환, prep/build_pidray.py)는 사전학습 비교 실험 (§ 3.9) ③ 조건에만 썼습니다. 이득이 없어 최종 모델과 전달 패키지에는 쓰지 않습니다 (라이선스: 학술 목적 한정). GDXray는 공식 배포 링크가 삭제되어 쓰지 않았습니다(재배포 금지 조건이라 비공식 사본도 쓰지 않음)
최종 조합	Telea 인페인팅(반경 3) 영상 → YOLOv8s ② COCO 사전학습, 입력 640, 실제 train 350장만으로 학습 (의사 라벨·합성 데이터 쓰지 않음) → 제품 영역 밖 검출 제거 → 판정 T_low 0.648 / T_high 0.684. 최종 가중치 runs/nb2/yolov8s_sl/weights/best.pt (seed 3개 중 val 최고, § 5)
요구 사항 ③	§ 5 : 최종 모델(seed 1), 제품 영역 밖 검출 제거, T_low 0.648 / T_high 0.684(val로 정함). test 실제 결함 76.7% 자동 · 20.9% 재검사 · 놓침 2.4%, 실제 영상 자동 오검출 0, 결함 없는 제품 자동 오판 3.6%, GT 없는 영상 재검사 3.2%. 다른 자리 결함 82% 놓침은 한계로 보고

7. 한계

- **결함 다양성 부족**: 모든 GT 결함이 같은 테스트피스(1~4px 점, 띠 끝 4곳, 감쇠율 약 0.5)입니다 (§ 3.6). 현재 test 점수는 "처음 보는 날에 같은 시편을 얼마나 잘 찾는가"이며, 다른 크기·위치·재질의 이물에 대한 성능은 아직 측정하지 못했습니다. 요구사항 ②(조건별 성능)는 § 4의 합성 평가(밀도·잡음·위치·크기·형상·재질 축)로 답합니다.
- **합성 데이터는 평가 전용**(팀 결정): 합성 test에서 드러난 사각지대(다른 위치·가장자리·작은·큰·비금속 이물)를 학습으로 보강하지 않습니다. 보강하려면 다양한 실제 이물 촬영 데이터가 필요합니다. 합성 test 결과도 합성이 실제 이물과 같다는 가정 위의 값입니다 (§ 4.9).
- **진짜 마커 없는 평가 영상이 없음**: 마커 제거 효과는 여러 방식으로 지운 test와 흔적 검사로 간접 확인했습니다 (§ 3.2.2).
- **평가 규모**: val 66장(결함 144), test 84장(결함 206). 결함 1개 = 재현율 약 0.5~0.7%p. seed 간 AP 편차가 0.01~0.05라 그보다 작은 차이는 구분하지 못합니다.
- **분할이 하나**: 날짜 묶음이 적어(장비별 10~17일) 분할에 따라 점수가 달라질 수 있습니다.
- **GT 없는 데이터의 지표**는 정확도가 아닌 일관성 지표입니다.

부록 A. 재현과 파일

실행 환경: 공용 anaconda 환경은 다른 사용자가 패키지를 바꿔(numpy 2.x로 pandas가 깨짐) 쓸 수 없어서, 프로젝트 전용 가상환경 .venv를 만들어 모든 실험을 돌렸습니다. 이 환경은 공용 패키지를 읽기만 하고, 아래 버전만 고정합니다: numpy 1.26.4, torch 2.7.1+cu118, torchvision 0.22.1+cu118. 이 환경에서 베이스라인 점수가 그대로 재현되는 것을 확인했습니다 (seed 0 test AP 0.9427). GPU는 RTX 4090(24GB) 3장 중 비어 있는 것을 사용했습니다. 모델 하나 학습에 약 16~20분(300 epoch)이 걸립니다.

```
PY=.venv/bin/python
$PY eda/extract.py          # 원본 인벤토리, 이미지·결함·마커 통계 (eda/out/)
$PY eda/figures.py          # 데이터 분석 그림 (f1~f9)
$PY eda/unlabeled.py        # GT 없는 데이터 통계·품질 판정 (u1~u3)
$PY prep/convert_coco_weights.py # 외부 가중치 변환 (weights/yolov3-spp.weights 필요)
```

```

$PY prep/build_dataset.py          # 마커 Telea 인페인팅(data/clean)·원본(data/marked) + (장비, 날짜) 분할
$PY prep/build_masked.py          # 마스킹 비교용 (data/masked)
$PY prep/build_marker_variants.py  # 마커 제거 방식 4종 (data/rm_ns, rm_dil, rm_bgfill, rm_biharm). 방
식 정의는 prep/rm_methods.py
$PY prep/build_unlabeled.py        # GT 없는 데이터: 인페인팅(data/unlabeled) + 역할
(data/splits/unlabeled_roles.csv)
$PY eda/split_figures.py          # 분할 그림 (d1~d5)
bash prep/run_train.sh v2/B_s0 0 clean 320 640 416 300 16 "" 0 # 베이스라인 (이름 GPU 데이터 최소 최대
평가크기 epoch 배치 초기값 seed)
bash prep/run_marker_factor.sh     # 실험 ① 원본·마스킹 학습 + 평가 + 흔적 검사
bash prep/run_marker_rm.sh        # 실험 ① 확장: 제거 방식 4종 학습, 21개 모델 × 입력 7종 평가, 흔적 검사 6종
$PY prep/build_cv_folds.py        # 실험 ②a 교차 검증 조각 (data/splits/cv3.csv)
bash prep/run_train.sh v2/CV_f0 1 cv3_f0 320 640 416 300 16 "" 0 # 조각별 교사 (f0, f1, f2)
$PY eval/pseudo/pl_methods_cv.py  # 실험 ②a 의사 라벨 방법 8가지 채점
bash prep/run_unlabeled_factor.sh  # 실험 ②b (의사 라벨 생성, 학생, 학습량 대조군, 평가)
$PY eval/evaluate.py --runs <run ...> --inputs clean --out eval/out_v2
$PY eval/v2_figures.py            # 실험 결과 그림 (x1~x4)
$PY eval/failure/collect_heldout.py # 실패 조건: 학습에 안 쓴 모델로 GT 500장 검출
$PY eval/failure/failure_analysis.py # 실패 조건: 결함별 농침·조건 (eval/failure/per_defect.csv)
$PY eda/diversity.py              # 데이터 다양성 정량화 (f10, f11, eda/diversity/)
$PY prep/synth/build_replica.py    # 합성 타당성 검증용 복제 데이터 (data/synth_val/). 합성 함수는
prep/synth/synth_core.py
$PY eval/synth/validate_replica.py --infer # V1~V4 판정, 옮겨 심기 T_self·T_cross 포함 (처음 실행 시 보
정 계수를 쓰고 끝남 → build_replica.py 다시 실행 후 한 번 더)
$PY eval/synth/stress_v0.py       # 스트레스 곡선 v0: 밀도·잡음 축 검출 (약 10분, GPU)
$PY eval/synth/stress_v0_check.py # 명목 대비 환산, 빈 자리 측정 편향
$PY eval/synth/stress_v0_fig2.py  # 스트레스 그림(s1)·한계값 표
$PY prep/build_handoff.py         # 모델 담당 전달 패키지 (부록 B)
bash prep/run_nb2.sh yolov8s 1 0 # 새 베이스라인 학습 (모델 GPU seed). dfine_s 는 third_party/D-FINE +
configs_nb2/dfine_s_kamp.yml
bash prep/run_nb2_reruns.sh yolov8s 1 # 새 베이스라인으로 기존 실험 다시 돌리기 (기본 평가 → 흔적 검사 → 실패
조건 → 합성 검증 → 스트레스, 추론만)
$PY eval/synth/stress_pos.py      # 위치 축 스트레스 (NB2_MODEL=yolov8s|dfine_s|<변형> 이면 새 모델, 없으
면 YOLOv3)
$PY eval/synth/stress_pos_summary.py # 위치 축 요약 (eval/out_nb2/pos_*.csv,
eda/fig/n2_stress_pos.png)
bash prep/run_pidray_pretrain.sh yolov8s 1 # 사전학습 조건 ③ 1단계 (COCO → PIDray). 2단계:
run_nb2.sh <모델> <gpu> <seed> pidray (조건 ①: scratch)
$PY eval/decision/collect_dets.py yolov8s dfine_s # 판정 기준용 검출 (실제·결함 지운·GT 없는 영상, 제품 영
역 표시)
$PY eval/decision/thresholds.py   # 자동 불량·재검사 임계값과 test 판정 결과
(eval/decision/thresholds.csv, summary.csv)
$PY eval/nb2_variants.py          # 모델 변형(사전학습) 비교표 (eval/out_nb2/variants.csv)
$PY prep/synth/gvxr_calibrate.py  # gVXR 보정: 실제 결함 = SUS304 구 → 장비별 픽셀 크기·기준 지름
(eval/synth/gvxr/calibration.csv, sensitivity.csv)
$PY prep/synth/build_gvxr_replica.py # gVXR 복제 검증 데이터 (data/synth_val/G_gen, G_fit, H_gvxr)
→ eval/synth/validate_replica.py --add
$PY eval/synth/stress_gvxr.py yolov8s dfine_s # 크기·형상·재질 축 (약 1시간,
eval/synth/gvxr/stress_site.csv)
$PY prep/synth/build_synth_test.py # 합성 test 패키지 (handoff/kamp_synth_test_v1, .zip).
$4.5·$4.6과 같은 자리·난수, 약 10분
$PY eval/synth/predict_synth_test.py yolov8s dfine_s # 패키지에 기존 모델을 돌려 보고서 수치 재현 확인
(eval/synth/synth_test/)
$PY prep/build_report_pdf.py      # REPORT.md → REPORT.pdf (headless Chrome)
$PY eda/synth_figures.py          # 합성 데이터 그림 (s3 복제 비교, s4 위치 축, s5 gVXR 축)
$PY eval/nb2_compare.py           # YOLOv3·YOLOv8s·D-FINE-S 비교표 (eval/out_nb2/compare_*.csv,
eda/fig/n1_stress_models.png)

```

\$PY prep/build_pidray.py # 외부 데이터 PIDray 흑백 변환 (사전학습 조건 ③). 원본:
data/external/pidray/ (공식 라벨 + HF 이미지)

경로	내용
data/splits/split.csv	GT 500장: 장비, 날짜, (장비, 날짜) 묶음, 세션, split
data/splits/unlabeled_roles.csv	GT 없는 2,020장의 역할
data/splits/cv3.csv	실험 ②㉠ train 교차 검증 조각
eda/out/raw_inventory.csv	원본 폴더 전체 인벤토리 (GT / GT 없음 / 제외)
data/clean, data/marked, data/masked	Telea 인페인팅 / 원본 / 마스크
data/rm_ns, data/rm_dil, data/rm_bgfill, data/rm_biharm	마커 제거 방식 비교용
data/unlabeled, data/pl_v2	GT 없는 데이터(Telea 인페인팅) / 의사 라벨
runs/v2/	베이스라인 B_s*, 실험 ① M_{marked,masked,rm_ns,rm_dil,rm_bgfill,rm_biharm}_s*, 실험 ② CV_f*, U1_p990_s*, U1_p1000_s*, U0ctrl_s*
eval/out_v2/metrics.csv	공식 TXT 기준 평가 결과 (모델 × 입력 × split)
eval/marker_v2/	흔적 검사 (trace_sites_<방식>.csv), 제거 영역과 결함 거리 (variant_check.csv)
eval/pseudo_v2/	의사 라벨 방법 비교(pl_methods_cv*.csv), 의사 라벨 품질, GT 없는 데이터 평가
eval/failure/	실패 조건 분석: 학습에 안 쓴 모델의 검출(dets_heldout.csv), 결함별 결과 (per_defect.csv), 오검출(per_fp.csv)
eval/synth/	합성 타당성 검증: 결함별 맞춤 값(replica_params.csv), 보정 계수 (od_calibration.csv), 판정(validation_summary.csv, classifier_auc.csv, validation_v4.csv), 시도 1 결과(attempt1_gauss/). 스트레스 곡선: 결함별 결과(stress_v0_per_defect*.csv), 오검출 (stress_v0_fp.csv), 한계값(stress_v0_limits.csv), 잡음 상관 (noise_corr.csv)
runs/nb2/, eval/out_nb2/	새 베이스라인 학습 결과(yolov8s_s*, dfine_s_s*) / 평가(metrics.csv, per_machine.csv, summary.csv)·비교표(compare_*.csv). 실패 조건·합성·스트 레스·흔적 검사 결과는 기존 폴더에 모델 이름을 붙여 저장 (eval/failure/per_defect_<모델>.csv, eval/synth/nb2_<모델>/, eval/synth/stress_v0_per_defect_<모델>.csv, eval/marker_nb2_<모델 >/)
eda/diversity/	결함별 크기·위치·감쇠·형상(defect_features.csv), 조건 요약(summary.csv), 제 품 비교(product_summary.csv)

부록 B. 모델 담당 전달 패키지

모델 담당은 다른 환경을 쓰고 프레임워크가 아직 정해지지 않아, 어떤 프레임워크에서도 쓸 수 있게 만들었습니다.

항목	내용
위치	handoff/kamp_xray_v2/ (압축본 handoff/kamp_xray_v2.zip 또는 .tar.gz, 각 18MB, 내용 동일, sha256 파 일 동봉)
이미지	Telea로 마커를 지운 8bit 흑백 PNG, images/{train,val,test}
라벨	YOLO 형식 labels/{train,val,test} (공식 TXT 그대로), COCO 형식 coco/instances_{split}.json, YOLO 설정 data.yaml

항목	내용
분할 근거	split_manifest.csv (장비 M1~M3, 날짜, 묶음, 세션)
도구	tools/evaluate.py: numpy·pandas만 필요. 예측 CSV(image_id, x1, y1, x2, y2, conf)를 받아 이 보고서와 같은 지표 계산. tools/verify_split.py: 자기 train/val/test 목록이 고정 분할과 같은지 검사
검증	베이스라인 3개 모델의 검출 결과를 tools/evaluate.py로 다시 계산한 test-val 6건이 내부 평가와 소수점까지 일치. COCO 박스와 YOLO 라벨의 중심 일치 확인. 분할 검사 스크립트가 올바른 목록은 통과, 틀린 목록은 실패로 판정하는 것 확인
안내 (README)	분할을 새로 만들지 말 것, test는 최종 성적에만, seed 3개 반복, 외부 데이터 사용 시 사유·방법·출처 명시, GT 없는 데이터는 요청 시 제공

B.2 합성 test 패키지 (평가 전용)

항목	내용
위치	handoff/kamp_synth_test_v1/ (압축본 handoff/kamp_synth_test_v1.zip, 506MB). 만드는 스크립트 prep/synth/build_synth_test.py
용도	조건별 성능 평가 전용, 학습·증강·임계값 결정에 쓰지 않음 (팀 결정 2026-10-06). 모델 담당이 자기 모델을 § 4.5· § 4.6과 같은 조건으로 썰 수 있게 함
배경	메인 패키지의 val 66장 / test 84장에서 실제 결함을 지운 영상(train 사진 사용 안 함). 실제 결함은 라벨에서도 빠지고 합성 물체만 라벨에 있음
세트	erased (결함 없는 제품 대응) 150장 / 위치 축 pos_canon_k{1.0, 0.5} 150장씩, pos_random_k{1.0, 0.5} 600장씩 / gVXR gvxr_size_* 7종, gvxr_shape_* 6종, gvxr_material_* 24종, 각 300장. 합계 영상 12,750장, 물체 37,600개
라벨	YOLO 형식(class 0). 옮겨 심기는 장비별 실제 GT 박스 중앙값(9 / 11 / 13px), gVXR는 이물 영역 외접 사각형 + 2px(최소 GT 중앙값). images.csv (영상별 세트·조건), objects.csv (물체별 중심·평가 영역·대비)
도구	tools/eval_synth.py: 메인 패키지와 같은 예측 CSV를 받아 세트별 검출률, 영상당 오검출, erased 반응 비율 계산. 맞춤 규칙은 § 4.5· § 4.6과 같음(중심 8px 안 또는 이물 영역 4px 확장 안, 신뢰도 ≥ 0.25)
검증	기존 모델(YOLOv8s ②, D-FINE-S ② × seed 3개)을 패키지에 돌려 tools/eval_synth.py로 계산한 검출률이 § 4.5· § 4.6 원본 결과와 82개 조건 모두 일치(차이 0). 패키지가 보고서와 같은 영상임을 확인